

TECHNOLOGIES IN EDUCATION  
**UNIVERSITY**<sup>NSU</sup>  
MICROELECTRONICS  
**INNOVATIONS**  
CATALYTIC MATERIALS  
ASSEMBLY POINT  
SCIENTIFIC LABORATORY  
**HYBRID MATERIALS**  
GEOPHYSICS  
**ENGINEERING**  
ENERGY CONSERVATION  
**BIOTECHNOLOGY**  
GEOCHEMISTRY  
NANOTECHNOLOGY  
**HIGH ENERGIES**  
SEMIOTICS  
**SCIENCE**  
MATHEMATICAL MODELING  
IT DEEP LEARNING BRAIN STUDY COGNITIVE TECHNOLOGIES  
ASTROPHYSICS BIOINFORMATICS  
**LASER PHYSICS**  
GLOBAL PRIORITY  
KNOWLEDGE ECONOMY  
**GEOLOGY**  
ARCHEOLOGY  
MATHEMATICAL MODELING

# Машинное обучение

## Семинар 1

Глушенко Андрей Валерьевич  
Институт Интеллектуальной  
Робототехники

# Обзор курса

- Github: <https://github.com/andreymarlin/ml-iir>
- Email: a.glushenko@g.nsu.ru
- Telegram: @gsswgg
- Форма аттестации – диф. зачёт по следующим критериям:
  - Посещаемость
  - Выполнение лабораторных работ
  - Выполнение кейса в команде (3 чел.)

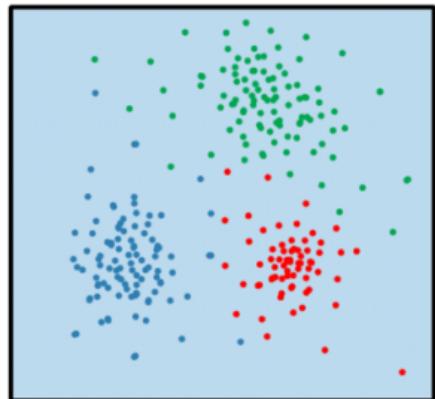
# Что такое машинное обучение?



# Типы машинного обучения

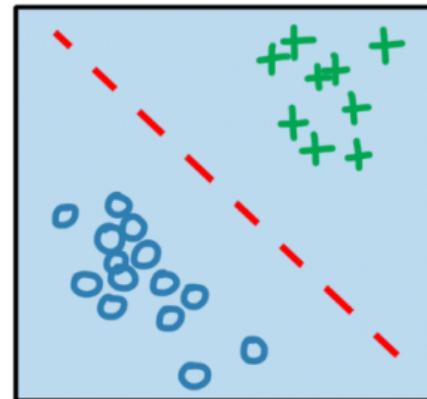
## machine learning

Обучение без учителя  
(Unsupervised learning)



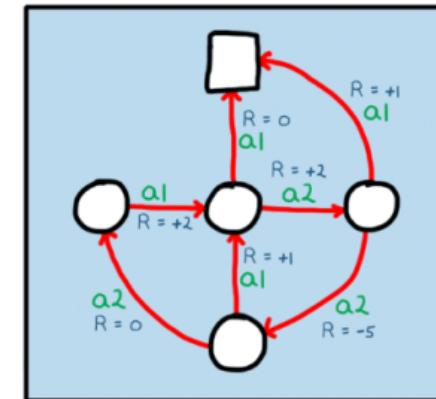
Неразмеченные данные  
Нет обратной связи  
Найти скрытую структуру

Обучение с учителем  
(Supervised learning)



Размеченные данные  
Предсказание  
следующего значения

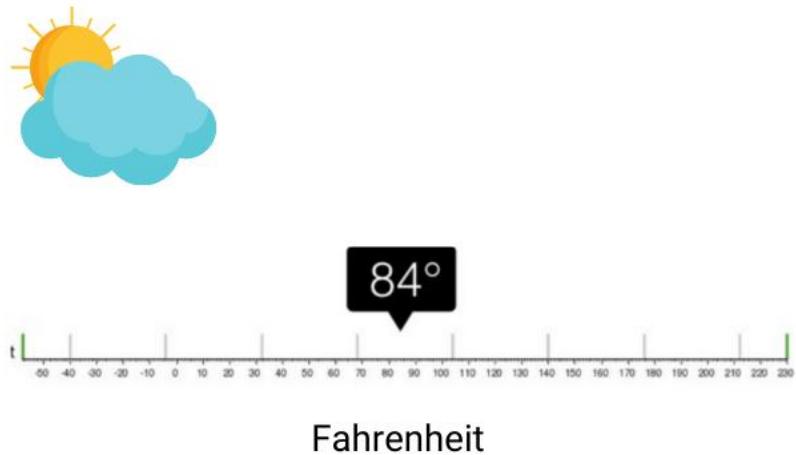
Обучение с подкреплением  
(Reinforcement learning)



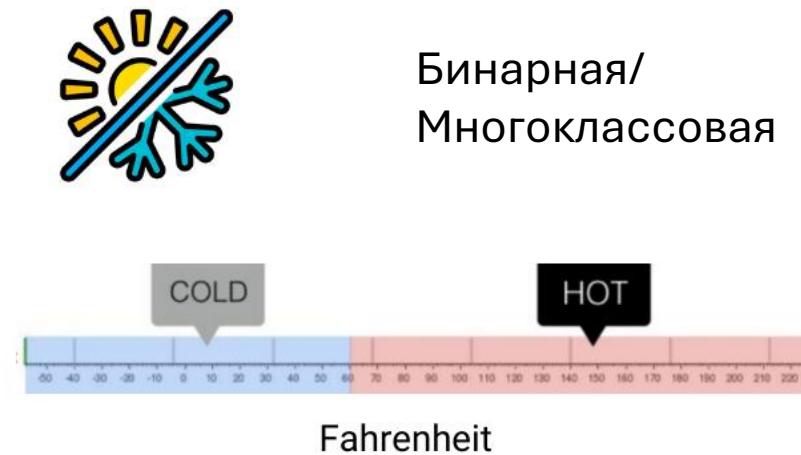
Принятие оптимальных решений  
Взаимодействие со средой  
Вознаграждения (или наказания) за результат

# Задачи обучения с учителем

## Регрессия (Regression)

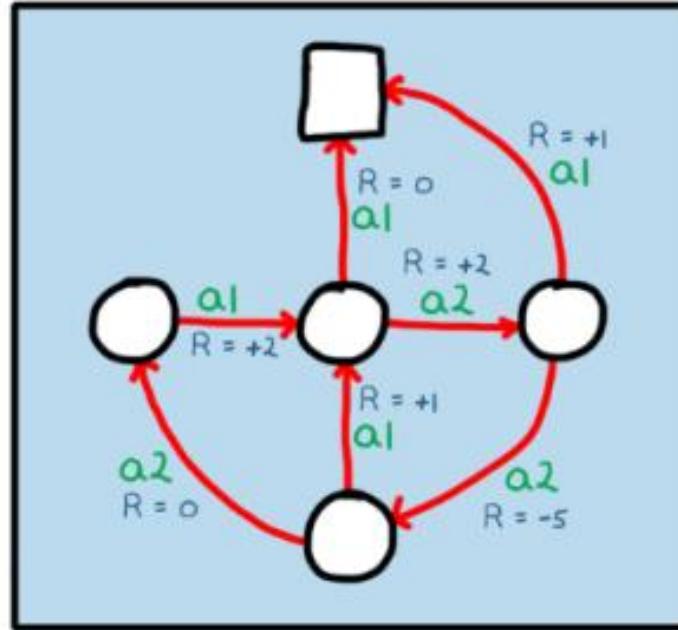


## Классификация (Classification)



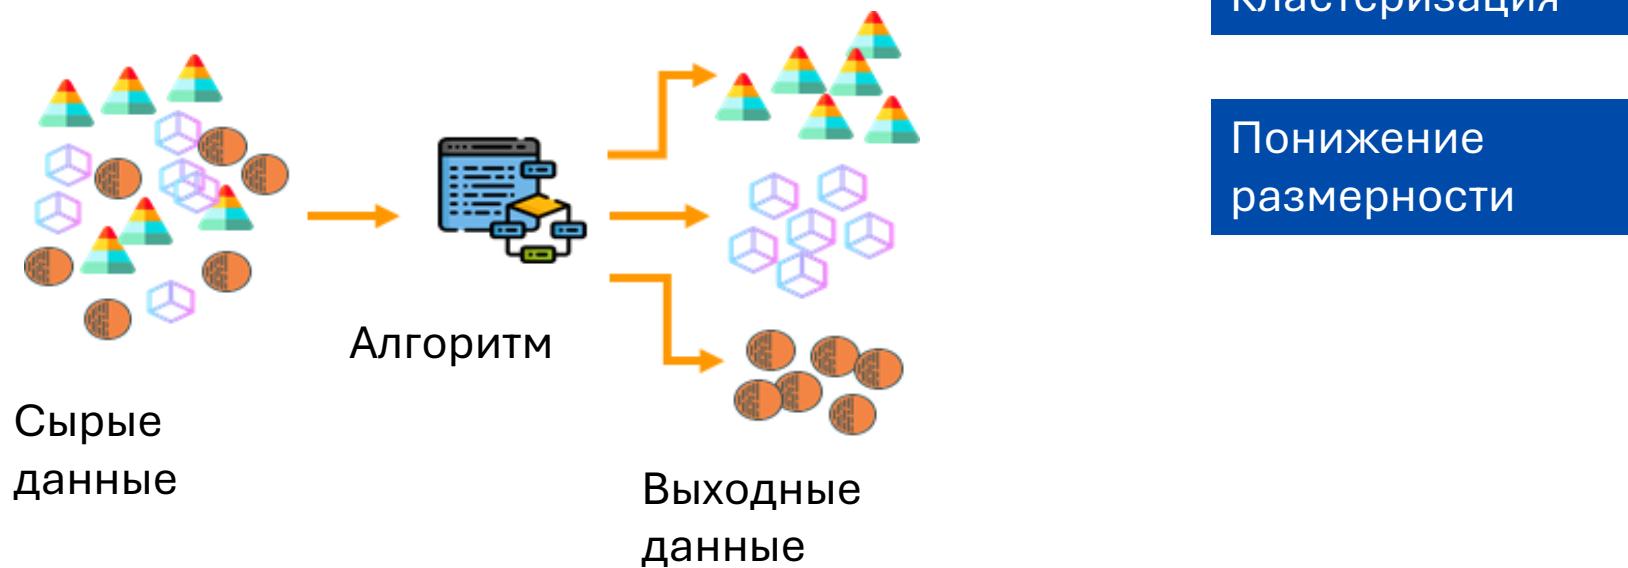
Source: <https://www.enjoyalgorithms.com/blogs/classification-and-regression-in-machine-learning>

# Обучение с подкреплением (Reinforcement learning)



Принятие оптимальных решений  
Взаимодействие со средой  
Вознаграждения (или наказания) за результат

# Задачи обучения без учителя



Source: <https://medium.com/analytics-vidhya/beginners-guide-to-unsupervised-learning-76a575c4e942>

Любой крупный бизнес сталкивается с потоком обращений клиентов. Ручная сортировка («это в бухгалтерию», «это к сисадминам») занимает время и стоит дорого. Автоматизация этого процесса — классическая задача в индустрии

Разработать веб-сервис, который позволяет пользователю ввести параметры недвижимости (площадь, район, этаж и т.д.) и получить прогноз стоимости, основанный на обученной модели машинного обучения.



В любой компании документооборот занимает огромное количество времени. Автоматическое извлечение таких полей, как «Номер договора», «Дата», «Сумма» и «Стороны», позволяет мгновенно каталогизировать архивы и искать нужные документы.

Определите тип задачи (Регрессия, Классификация или Кластеризация) для следующих сценариев:

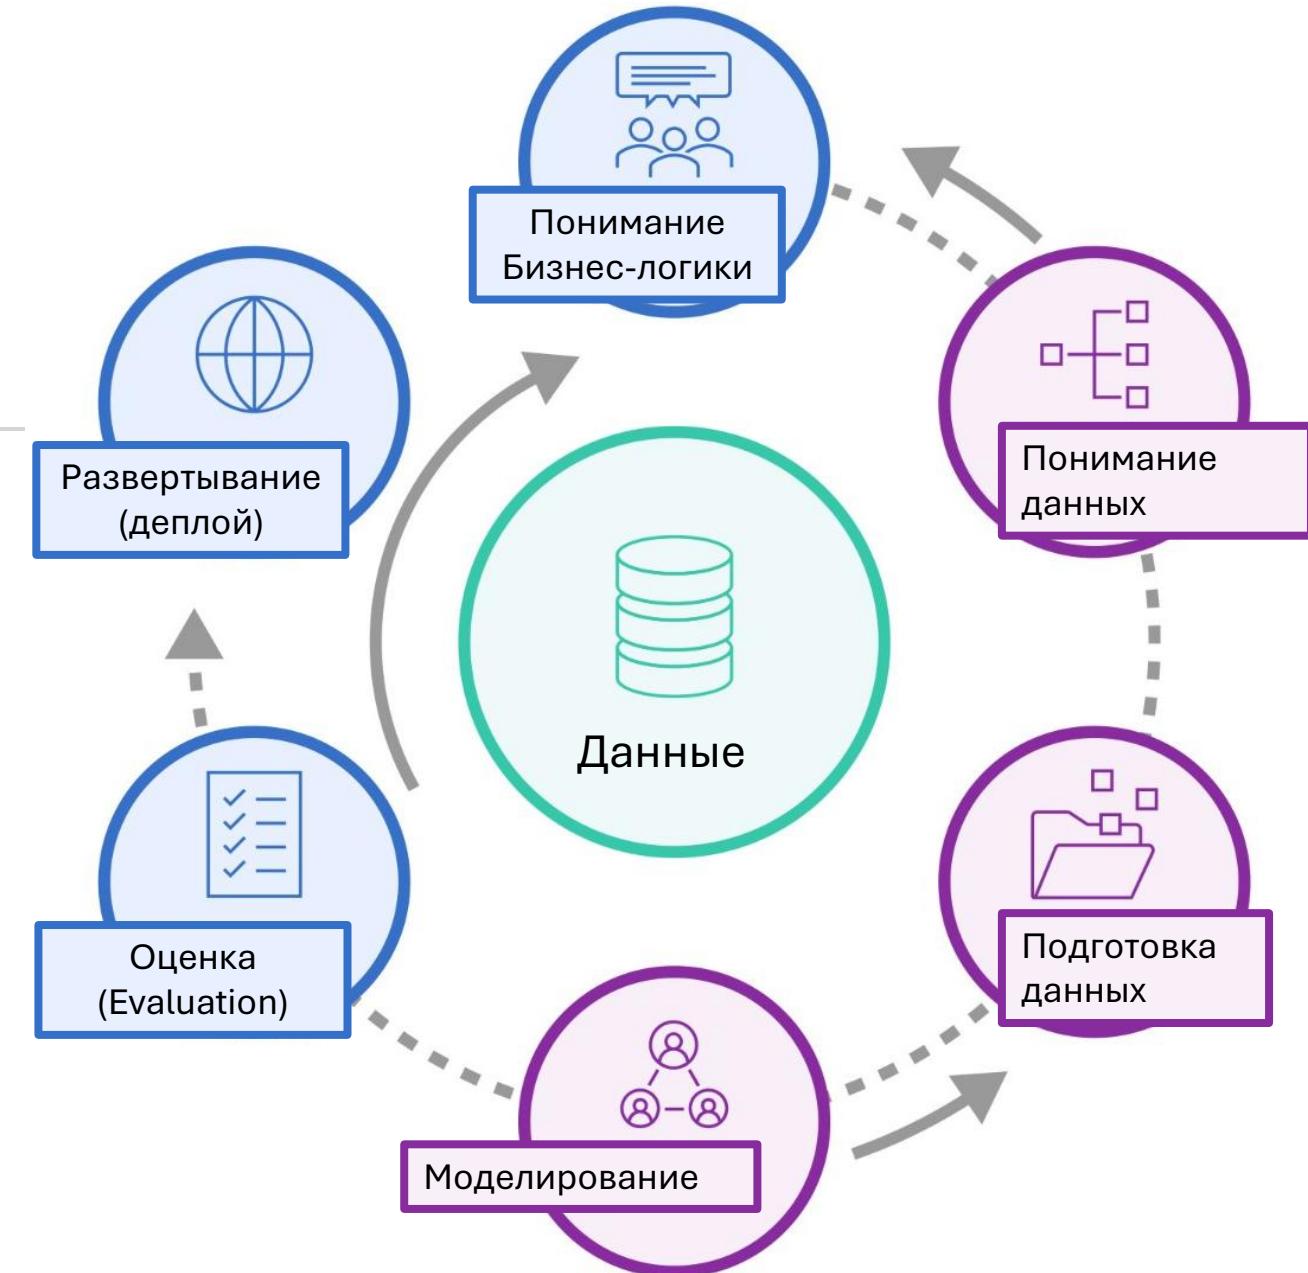
- А) Банк хочет предсказать вероятность (0 или 1), вернет ли клиент кредит.
- Б) Риелтор хочет оценить стоимость квартиры в рублях на основе её площади и района.
- В) Маркетолог хочет разбить базу клиентов на сегменты по покупательскому поведению, не зная заранее, какие это сегменты.



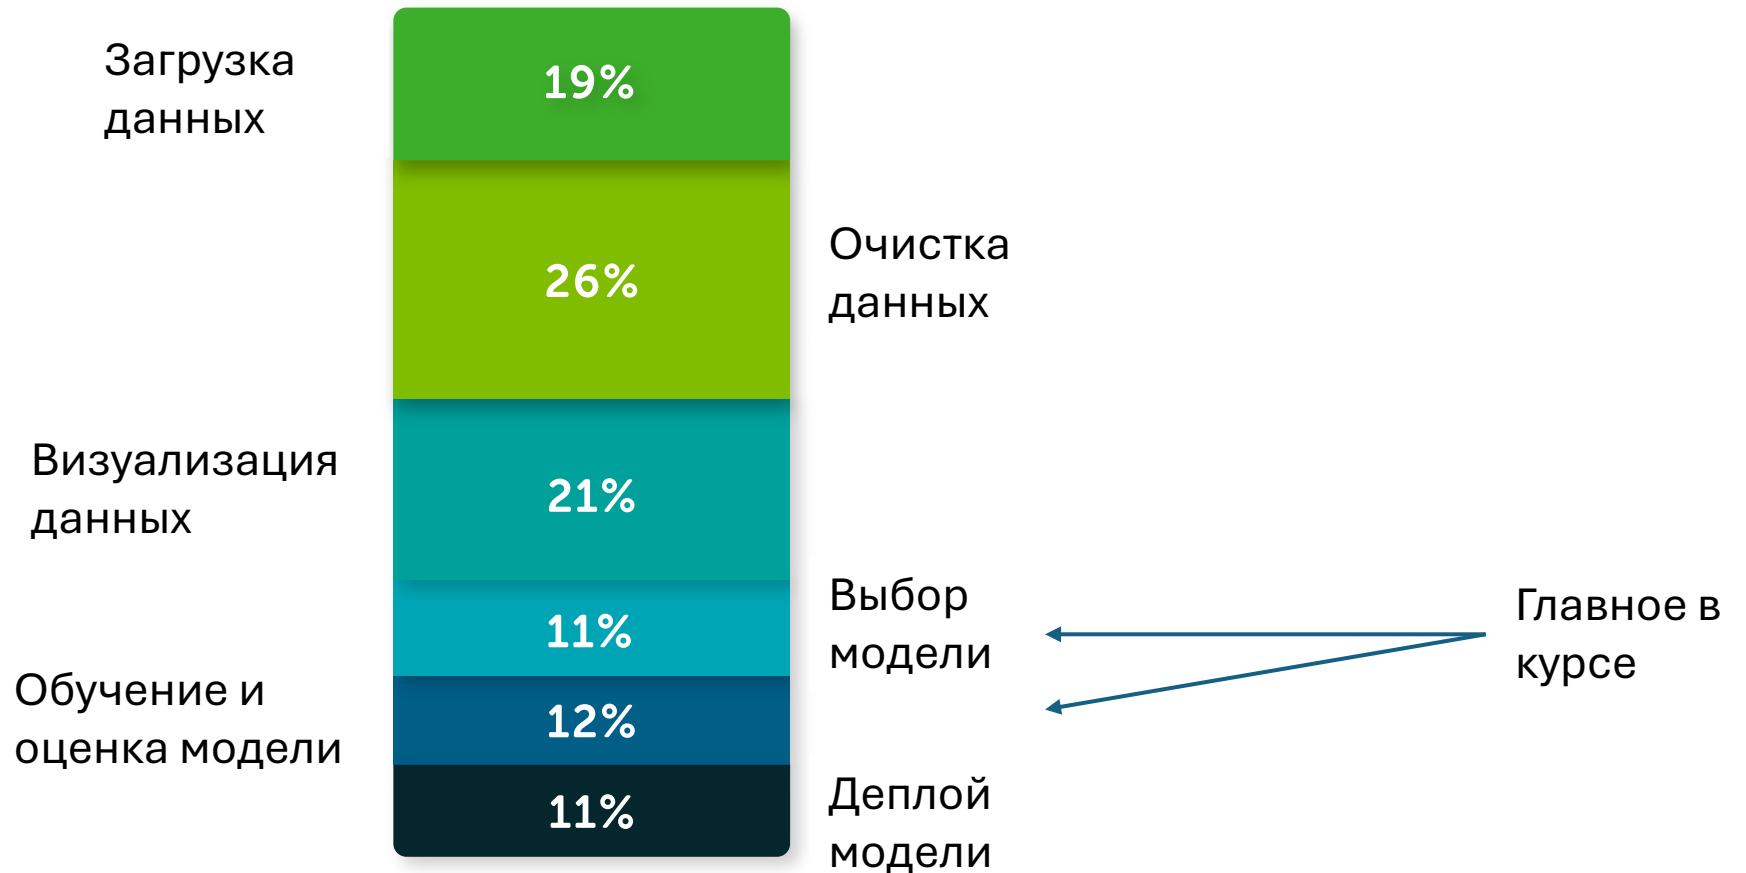
Почему для предсказания погоды (температуры) классическая логистическая регрессия (классификатор) может не подойти, а линейная регрессия подойдет?

# Цикл жизни дата-майнинга

Cross-Industry Standard Process for Data Mining (CRISP-DM)



# Затраты для выполнения задач ML



Source: <https://www.anaconda.com/resources/whitepapers/state-of-data-science-2020>

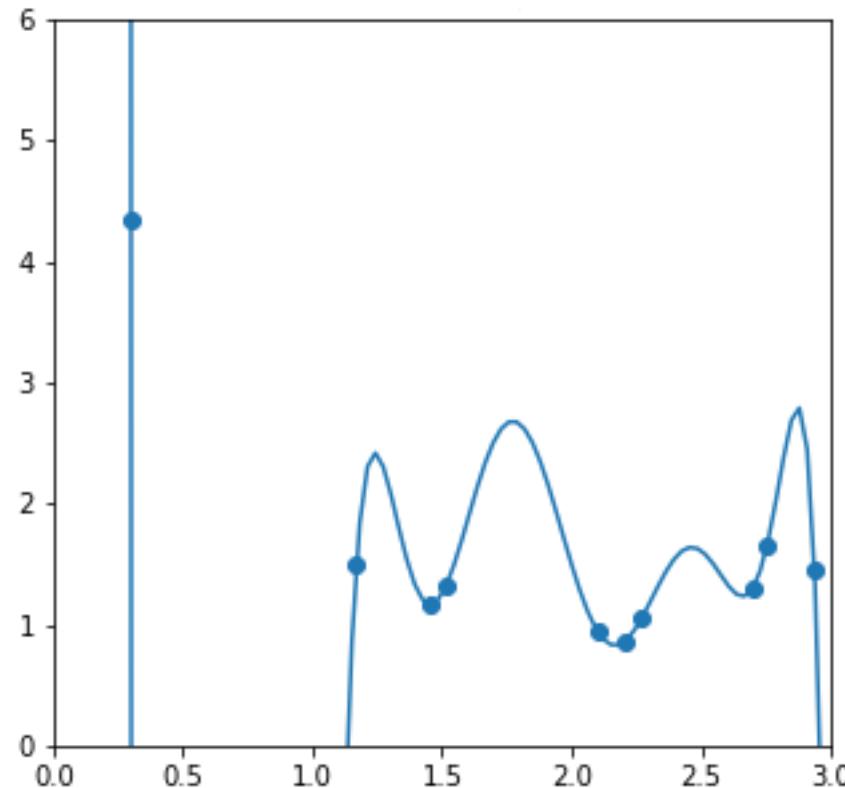
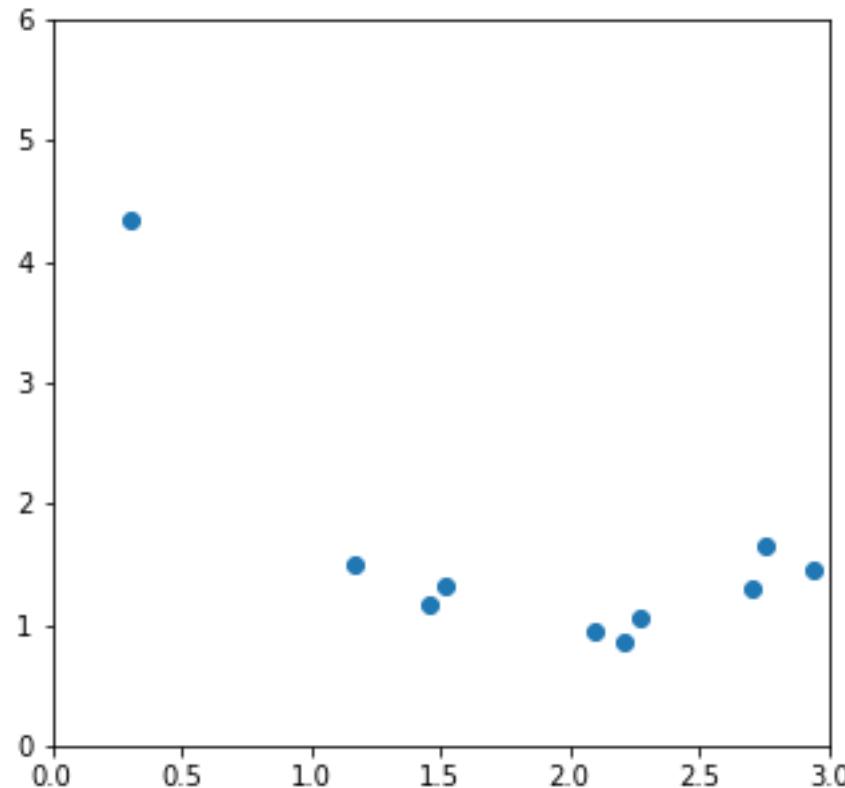
# Компоненты пайплайна машинного обучения

- Входные данные
- Признаки
- Модель
- Предсказание модели
- Метрики оценки

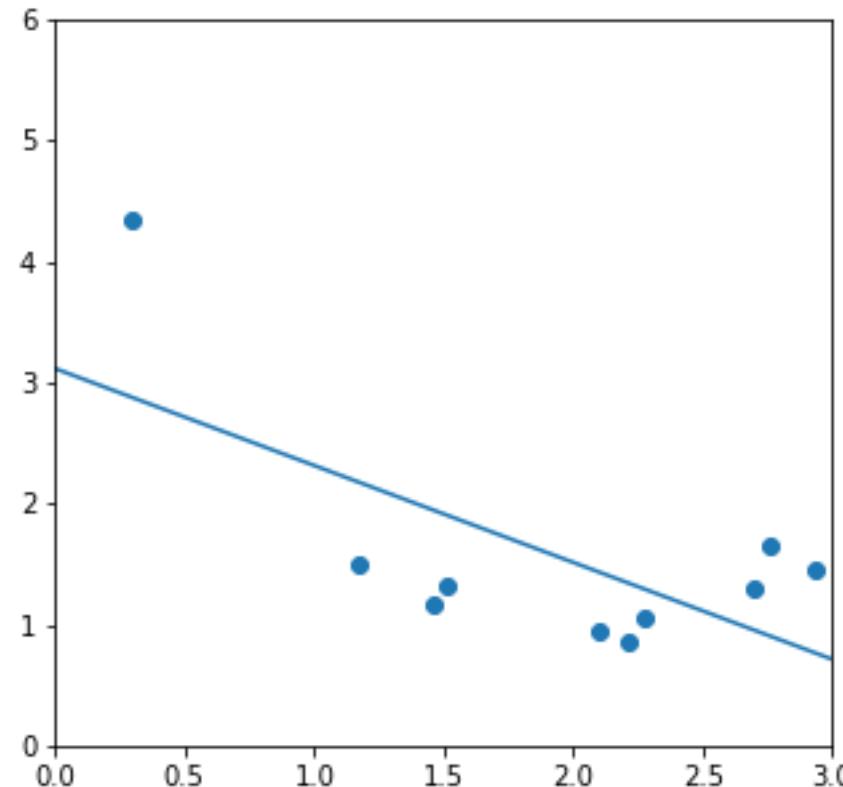
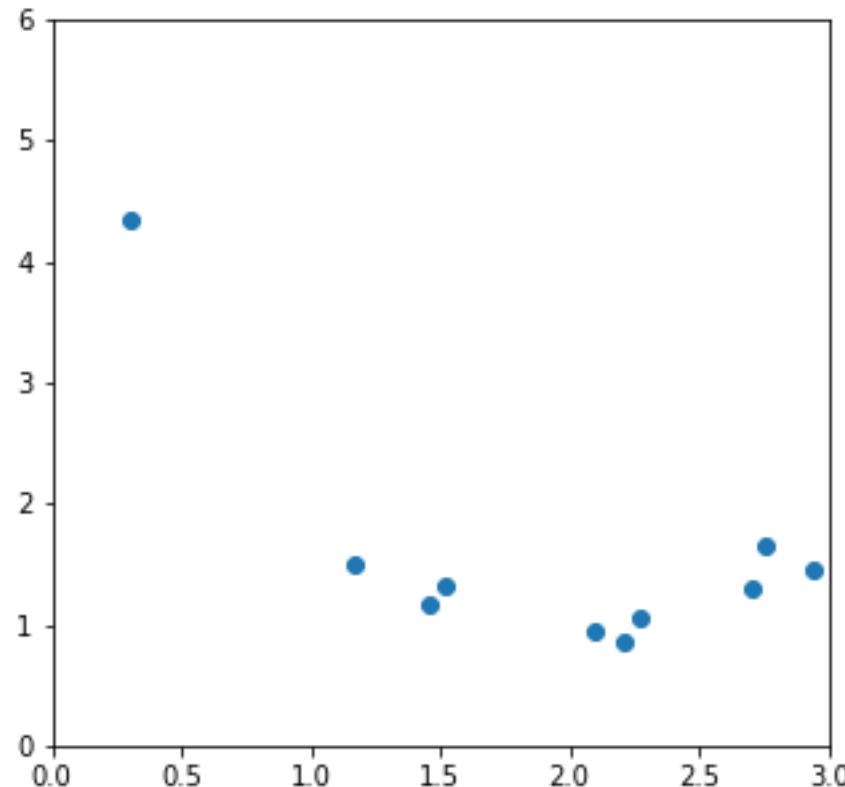
# Практические асpekты

Недообучение и переобучение  
Разделение на обучающую,  
валидационную и тестовую выборки  
Кросс-валидация  
Метрики

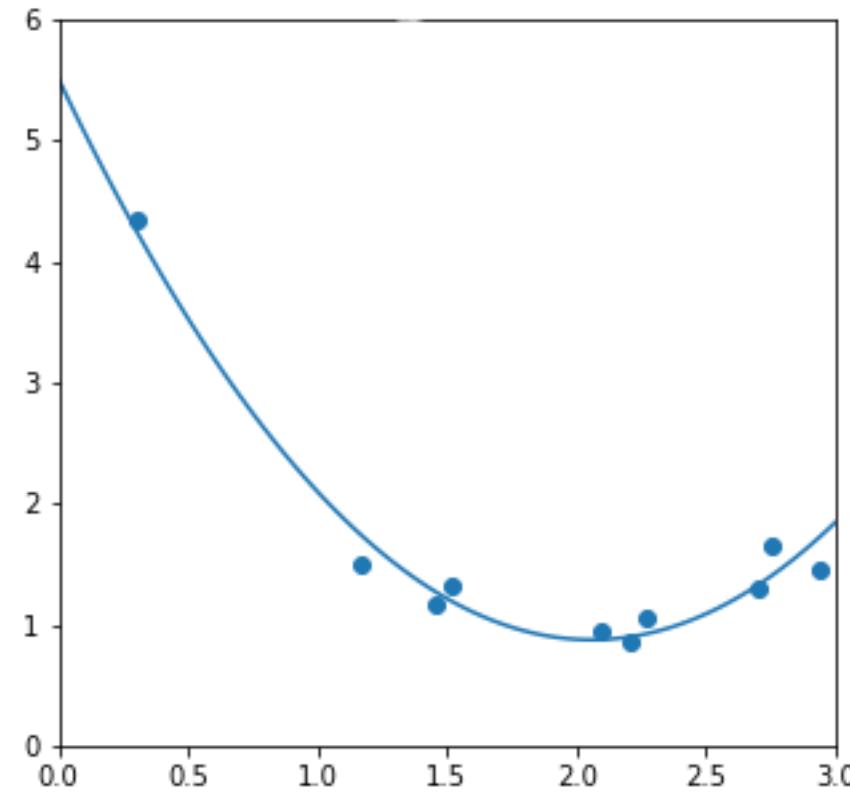
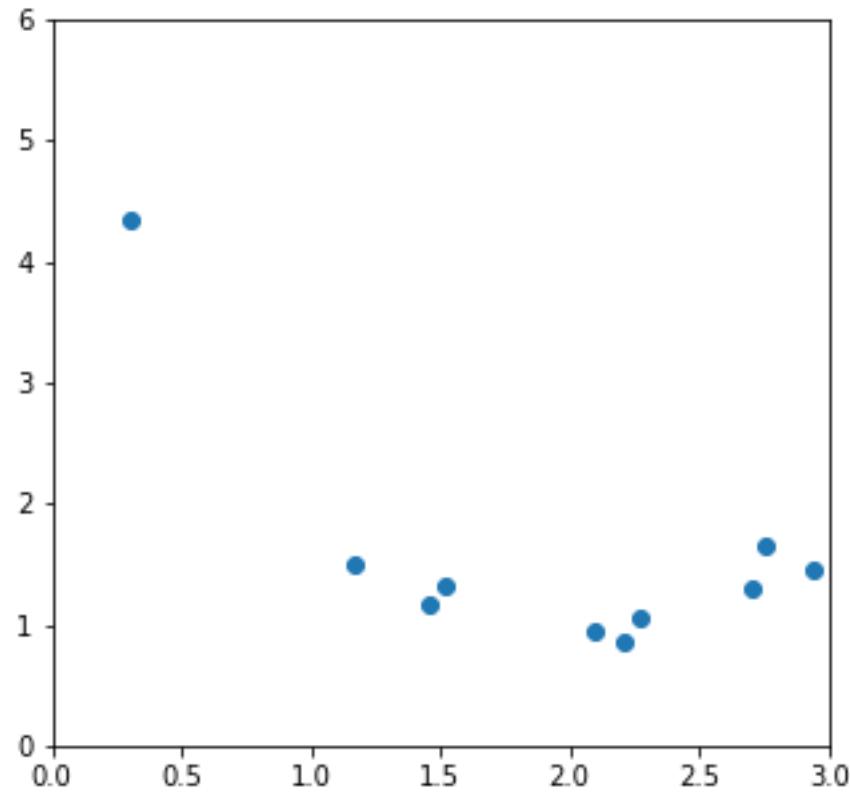
# Выбираем класс функции



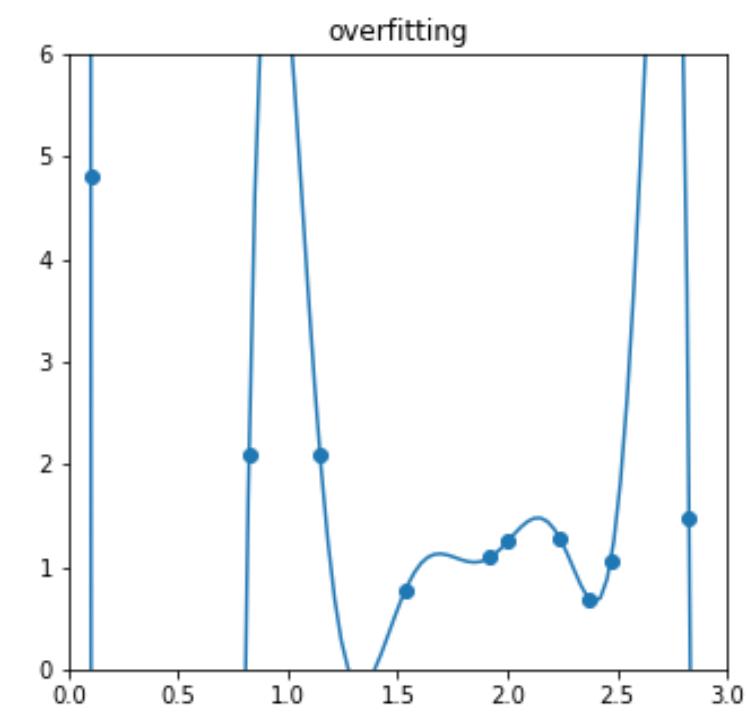
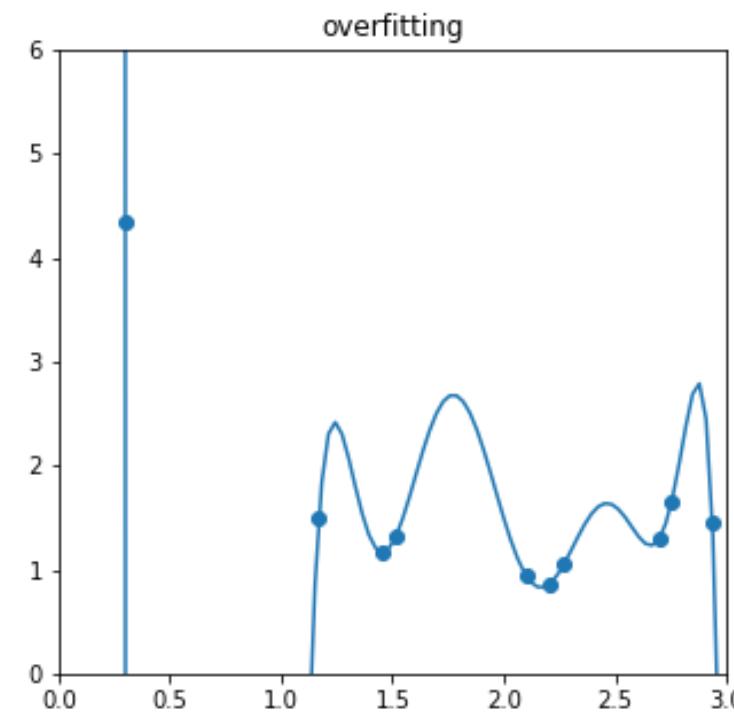
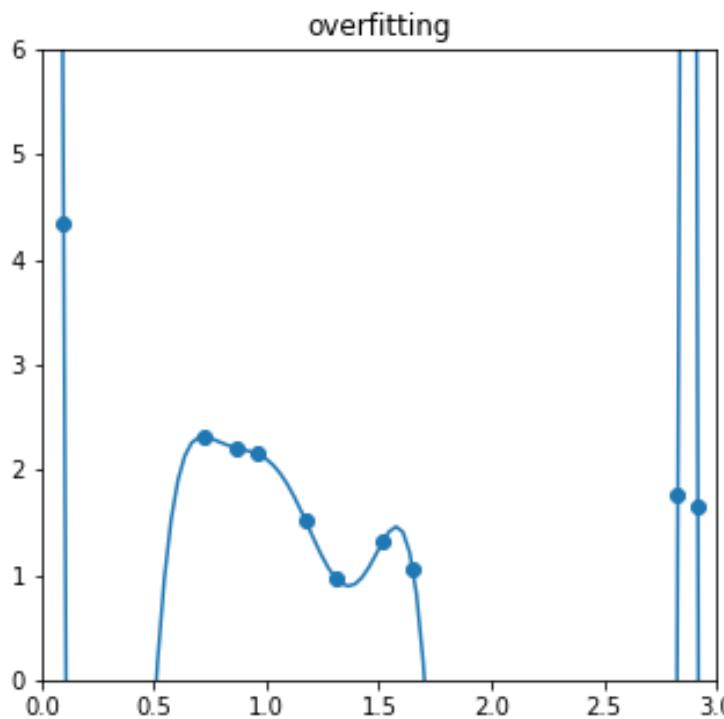
# Выбираем класс функции



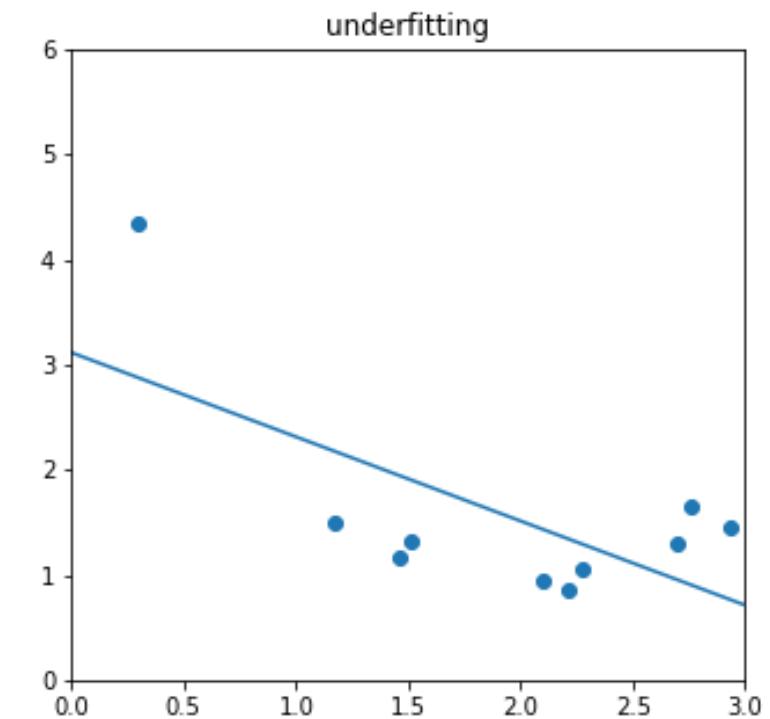
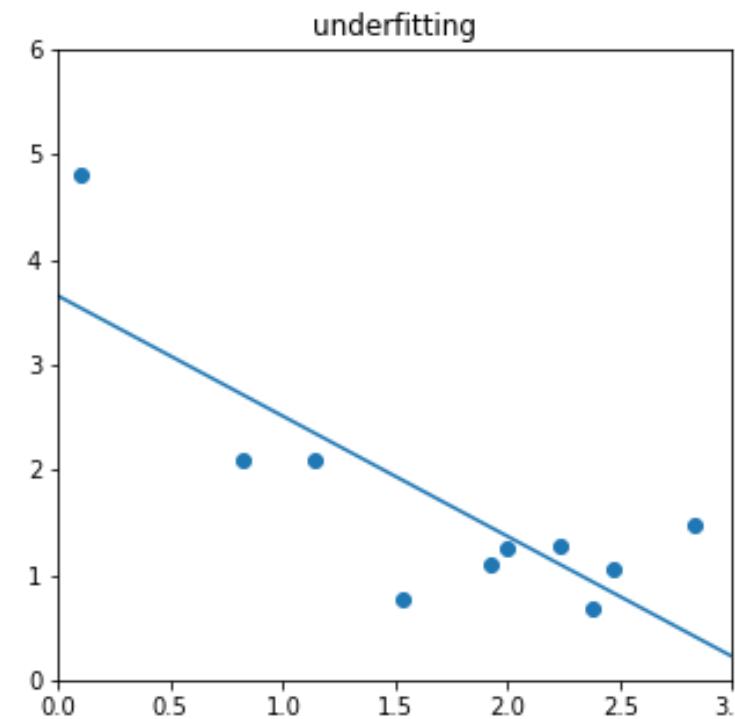
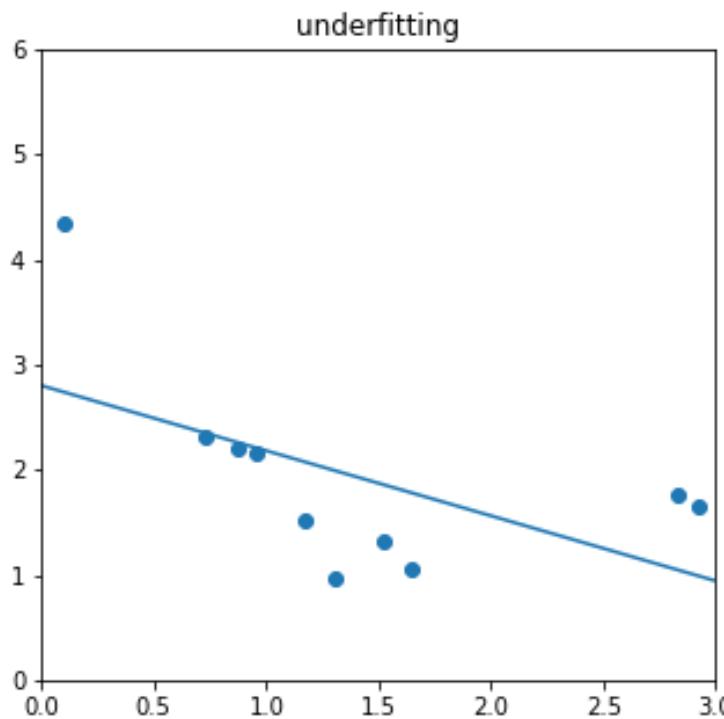
# Выбираем класс функции



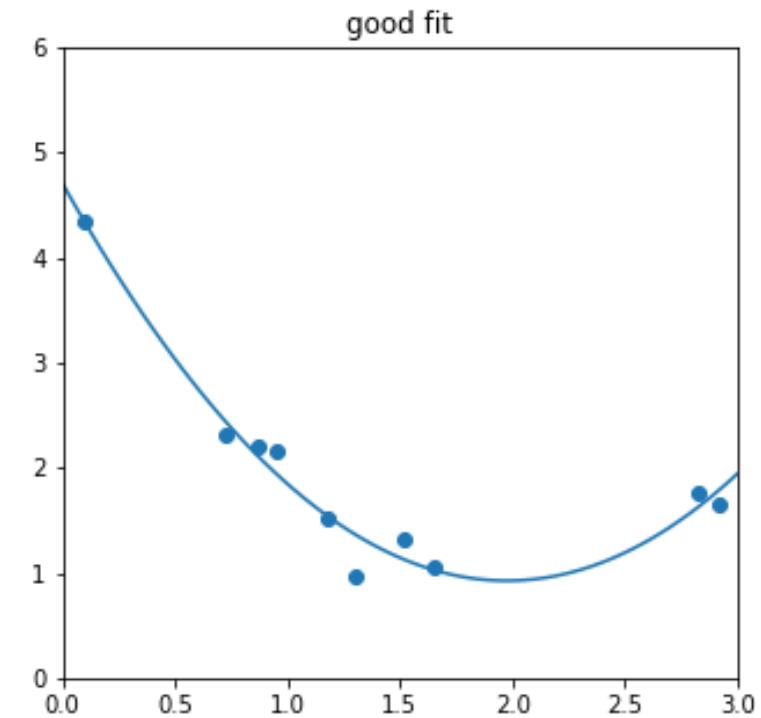
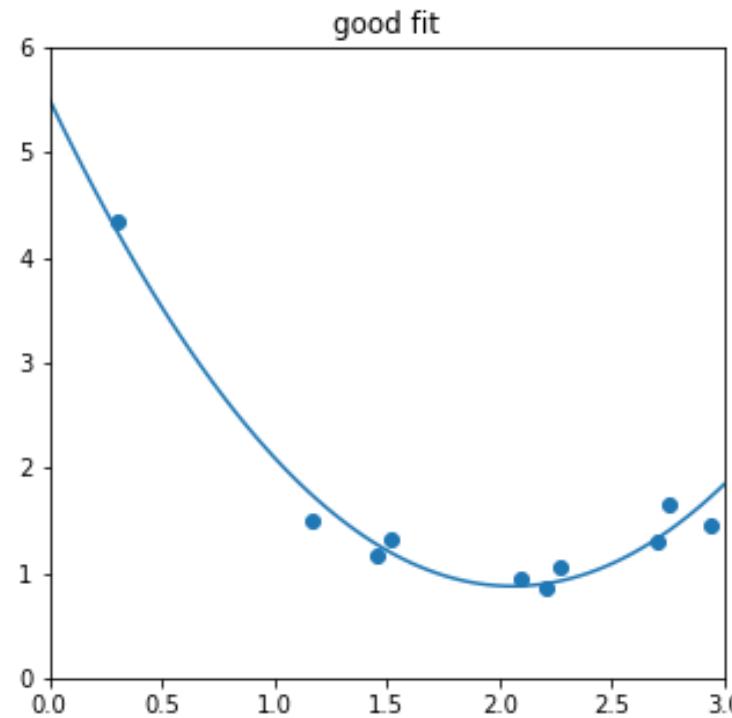
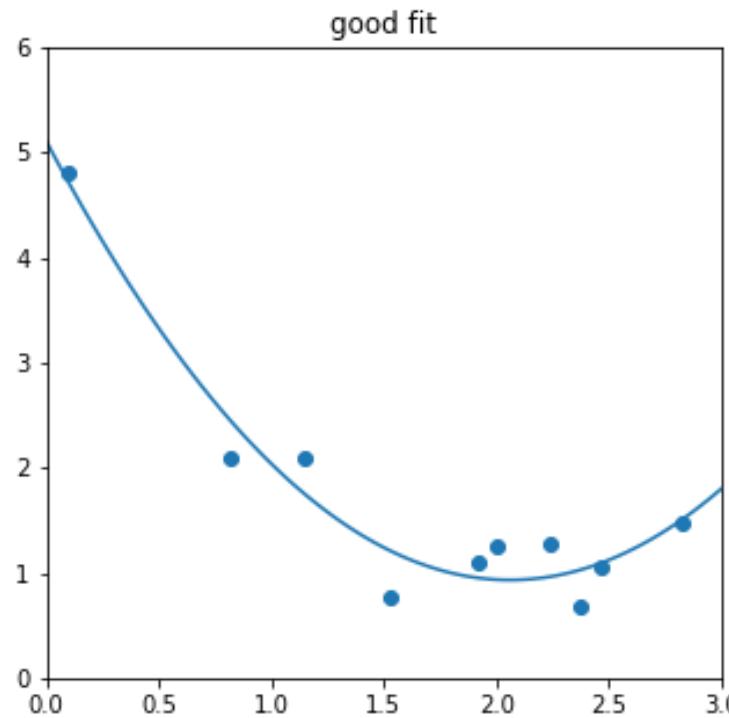
# Разброс (Variance), переобучение



# Смещение (Bias), недообучение



# Оптимальные разброс и смещение



# Переобучение (overfitting) и недообучение (underfitting)

- Модель с высоким смещением и низким разбросом (дисперсией) является недообученной моделью. Она недостаточно точно отражает статистические взаимосвязи в наших данных.
- Модель с высоким разбросом (дисперсией) и низким смещением является переобученной моделью, поскольку она улавливает взаимосвязи, слишком специфичные для конкретных данных, на которых мы ее обучаем. Эти взаимосвязи могут отсутствовать в общем распределении и, вероятно, являются ложными.

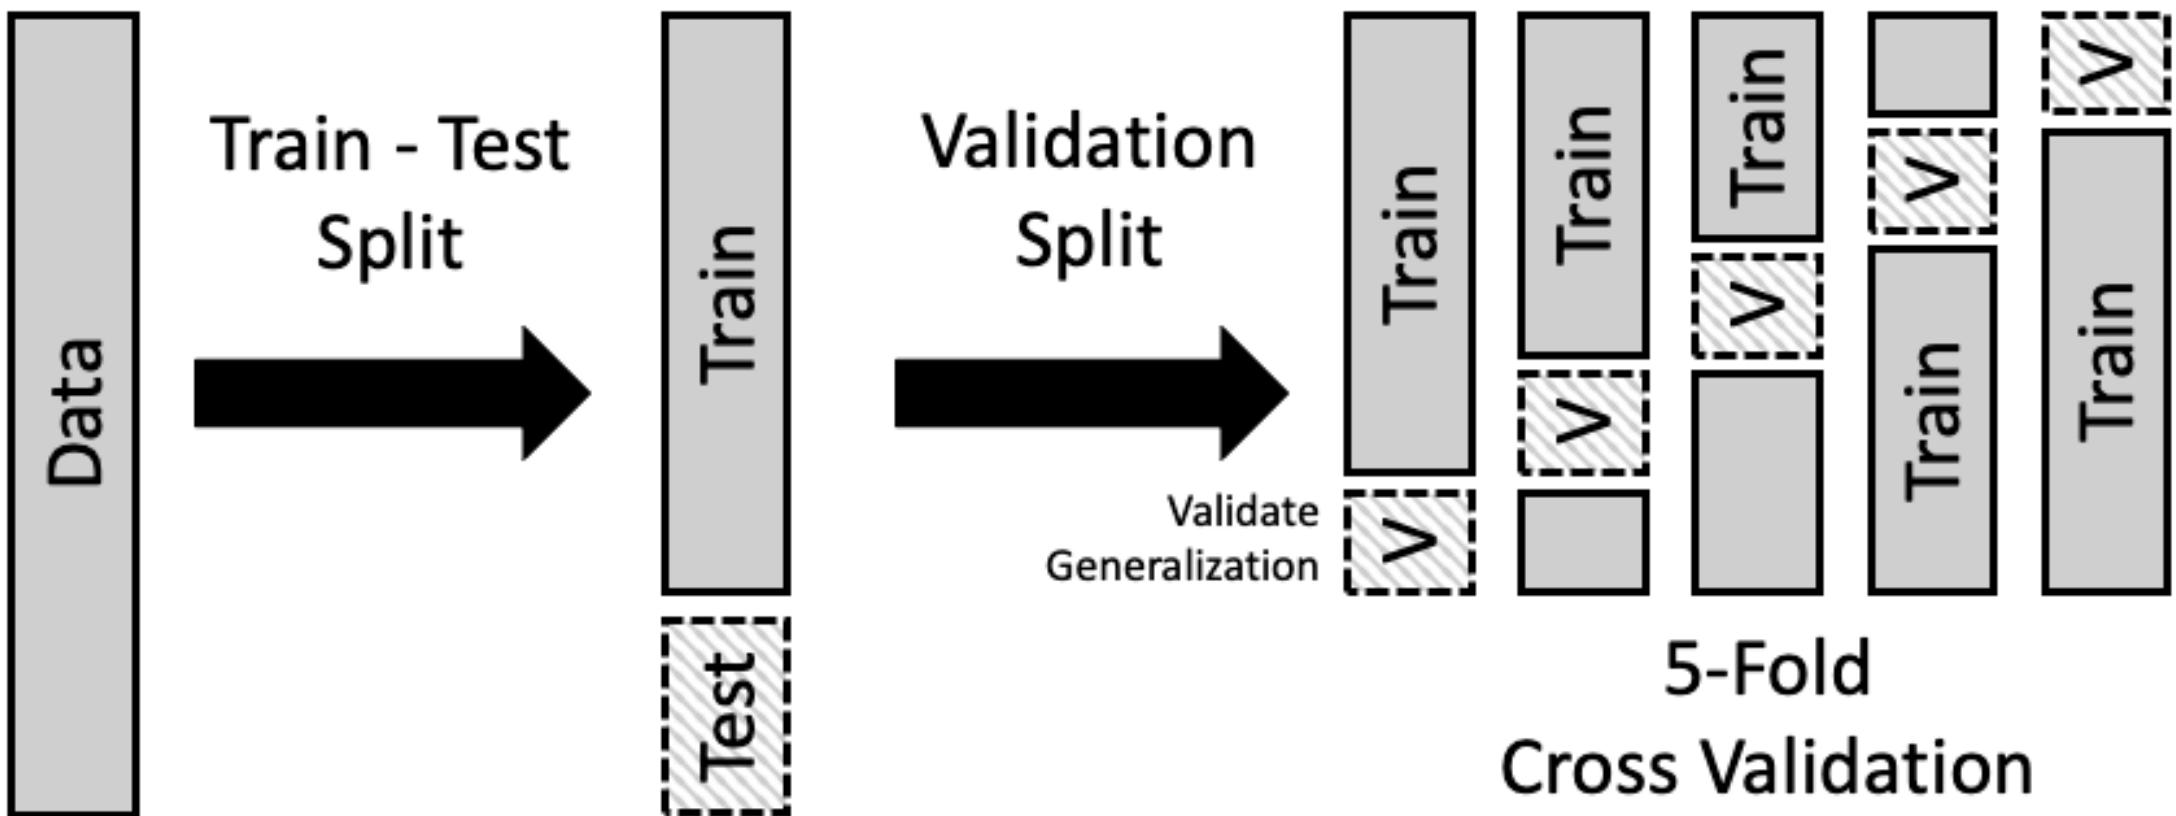
# Разделение датасета (Dataset splitting)

- **Тренировочный набор данных**
  - Используется для обучения модели, позволяя ей изучать закономерности и взаимосвязи.
  - Как правило, составляет наибольшую часть данных (например, 60-70%).
- **Валидационный набор данных**
  - Используется для настройки параметров модели и предотвращения переобучения.
  - Помогает оценить производительность модели во время обучения, но не используется для непосредственного обучения модели.
- **Тестовый набор данных**
  - Полностью отдельный набор данных, используемый для окончательной оценки модели.
  - Обеспечивает объективную оценку производительности модели на новых данных.

# Кросс валидация

- **Цель:** Подход, позволяющий максимально эффективно использовать данные для обучения и валидации.
- **Процесс:** Набор данных разбивается на  $k$  «складок». Каждая складка используется в качестве валидационного набора, а оставшиеся  $k-1$  складки — для обучения.
- **Распространенный подход:**  $k$ -складочная перекрестная валидация (например, 5-складочная), где результаты усредняются по всем складкам.
- **Преимущество:** Обеспечивает более надежную оценку, снижая риск переобучения и недообучения.

# Кросс-валидация



# Данные в машинном обучении

- Данные — основа. Модели полагаются на данные для обучения и прогнозирования.
- Качество имеет значение. Высококачественные данные = точные модели; некачественные данные = неточные, предвзятые результаты.
- Более эффективные решения. Чистые данные приводят к полезным выводам, которые способствуют принятию более эффективных решений.
- Снижает предвзятость. Репрезентативные данные помогают обеспечить справедливые и этичные результаты работы ИИ.
- Вывод: «Хорошие данные = хорошие модели».

# Вызовы при работе с данными

# 1. Проблемы качества и целостности

- **Отсутствующие данные:** Данные часто неполны из-за незарегистрированных значений или ошибок во время сбора.
- **Шумные данные:** Данные со случайными ошибками или шумом, часто требующие методов очистки или шумоподавления.
- **Выбросы:** Экстремальные значения, которые могут искажать модели, особенно в чувствительных алгоритмах.
- **Дублирующиеся данные:** Множественные записи для одной и той же сущности могут исказить модель, придавая чрезмерный вес определенной информации.
- **Неправильные метки:** Неправильная маркировка в тестовых наборах данных может сбить с толку модели и снизить точность.

## 2. Проблемы распределения данных

- **Несбалансированные данные:** Непропорциональное представление классов, что может смещать модели в сторону преобладающего класса.
- **Асимметричное распределение данных:** Сильно асимметричные признаки могут влиять на точность модели, особенно для алгоритмов, предполагающих нормальное распределение.
- **Перекрытие границ классов:** Плохо определенные границы между классами затрудняют классификацию.
- **Временной дрейф (дрейф концепций):** Статистические свойства данных меняются со временем, что приводит к устареванию моделей.

### 3. Проблемы с признаками данных

- **Нерелевантные признаки:** Неинформационные признаки добавляют шум в процесс обучения модели.
- **Высокая размерность (проклятие размерности):** Слишком много признаков увеличивает вычислительную сложность и риск переобучения.
- **Взаимодействие признаков:** Сложные взаимосвязи между признаками трудно выявить.
- **Перекрытие границ классов:** Перекрывающиеся признаки затрудняют различение классов моделями.

# 4. Проблемы форматов представления данных

- **Несогласованное форматирование:** Различия в форматах данных (например, дат или единиц измерения) приводят к ошибкам обработки.
- **Гетерогенные источники данных:** Данные из разных источников с различными форматами и структурами усложняют интеграцию.
- **Неструктурированные данные:** Текст, изображения или аудио требуют специальной обработки для машинного обучения.

# 5. Безопасность данных

- **Вопросы конфиденциальности:** Конфиденциальная информация должна быть анонимизирована или обрабатываться с осторожностью.
- **Законы о защите данных:** Необходимо соблюдение таких правил, как GDPR или HIPAA.
- **Проблемы безопасности:** Утечки или нарушения безопасности данных могут поставить под угрозу конфиденциальные наборы данных.

# 6. Вызовы при разметке данных

- **Недостаточная разметка:** Небольшие или неправильно размеченные наборы данных снижают качество модели.
- **Дорогие процессы разметки:** Разметка вручную, особенно в специализированных областях (например, в медицине), обходится дорого.
- **Неоднозначность классов:** Неоднозначные метки затрудняют точное обучение моделей.

# Что такое предобработка данных?



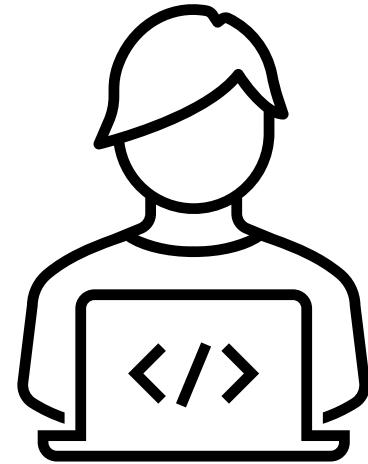
# Ресурсы для изучения ML

- Scikit learn: <https://scikit-learn.org/stable/>
- Kaggle: <https://www.kaggle.com/>
- Machine Learning Mastery: <https://machinelearningmastery.com/>
- Books: <https://github.com/josephmisiti/awesome-machine-learning/blob/master/books.md>

# Практика

Ресурсы для изучения ML

Лабораторные работы



34