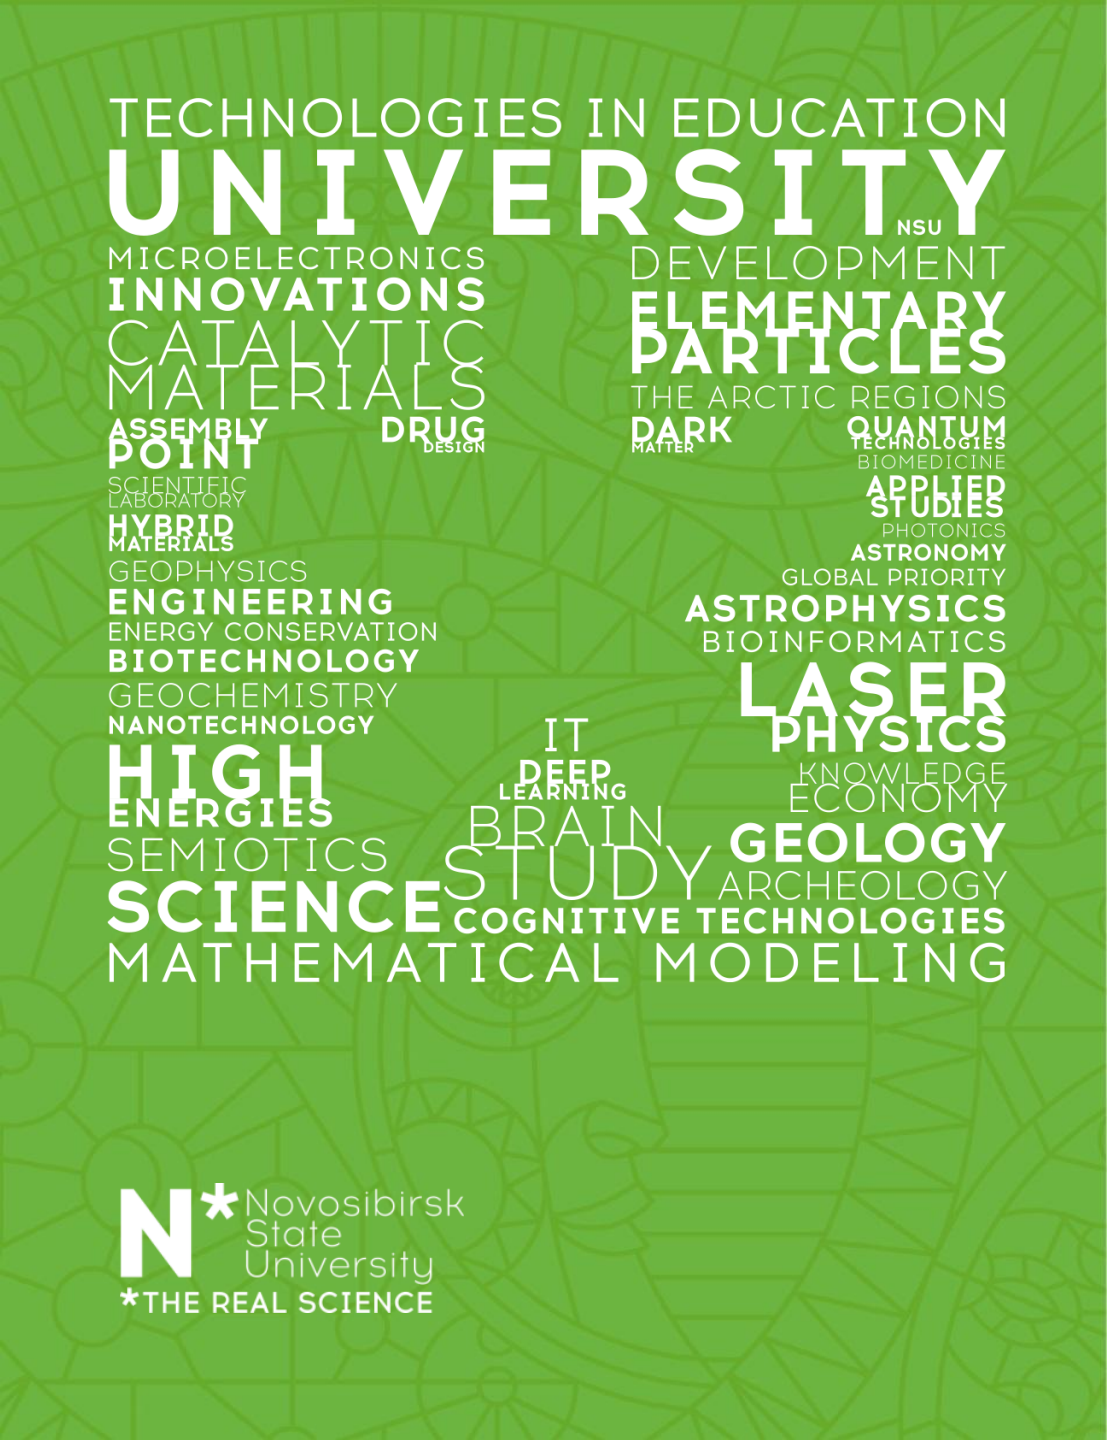

Машинное обучение
Семинар 5

Глушенко Андрей Валерьевич
Институт Интеллектуальной Робототехники

Задача классификации

Классификация — это процесс обучения модели предсказывать, к какой из заранее известных категорий (классов) относится объект.

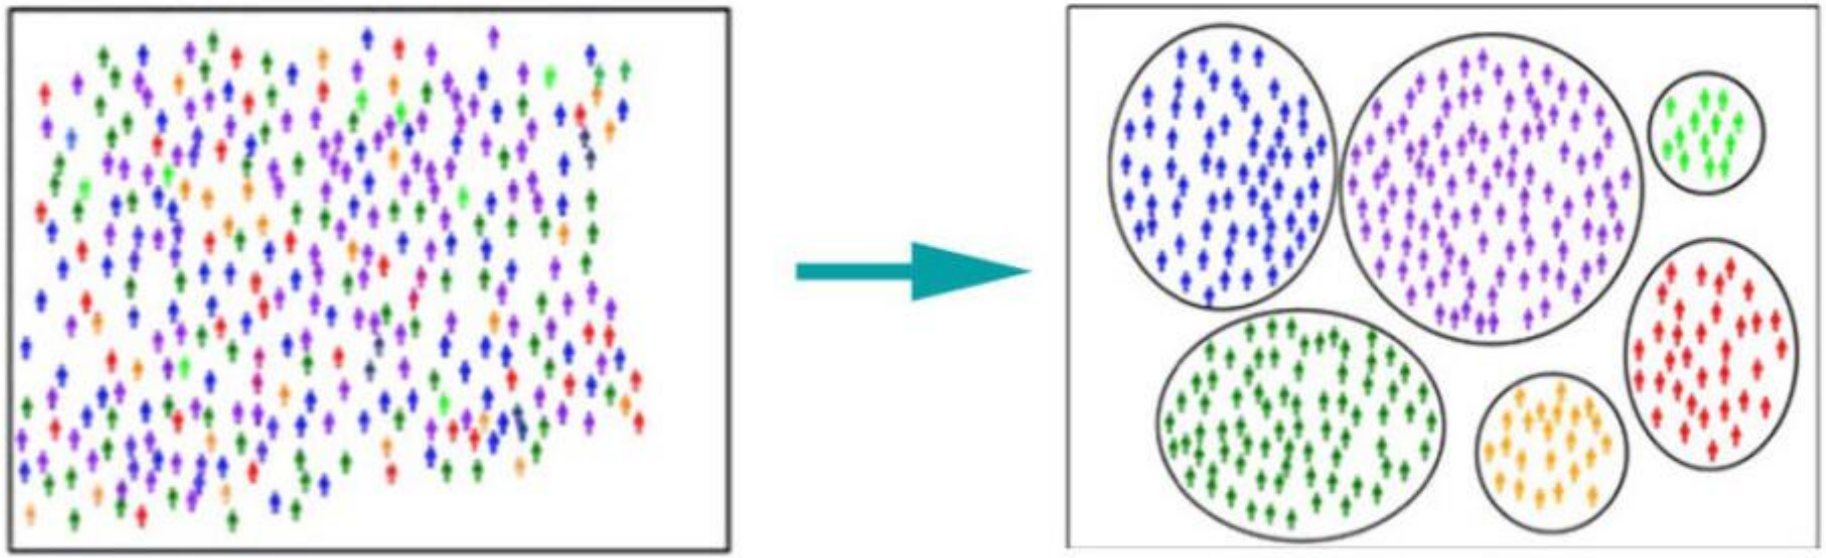

Основные типы классификации

- **Бинарная (Binary):** Всего два варианта.
  - *Пример:* Спам или не спам; болен человек или здоров.
- **Мультиклассовая (Multi-class):** Вариантов больше двух, выбрать нужно один.
  - *Пример:* Распознавание цифр от 0 до 9; определение породы собаки по фото.
- **Мультиметочная (Multi-label):** Объекту можно присвоить несколько тегов.
  - *Пример:* Статья на сайте может относиться одновременно к темам «Политика», «Экономика» и «Технологии»

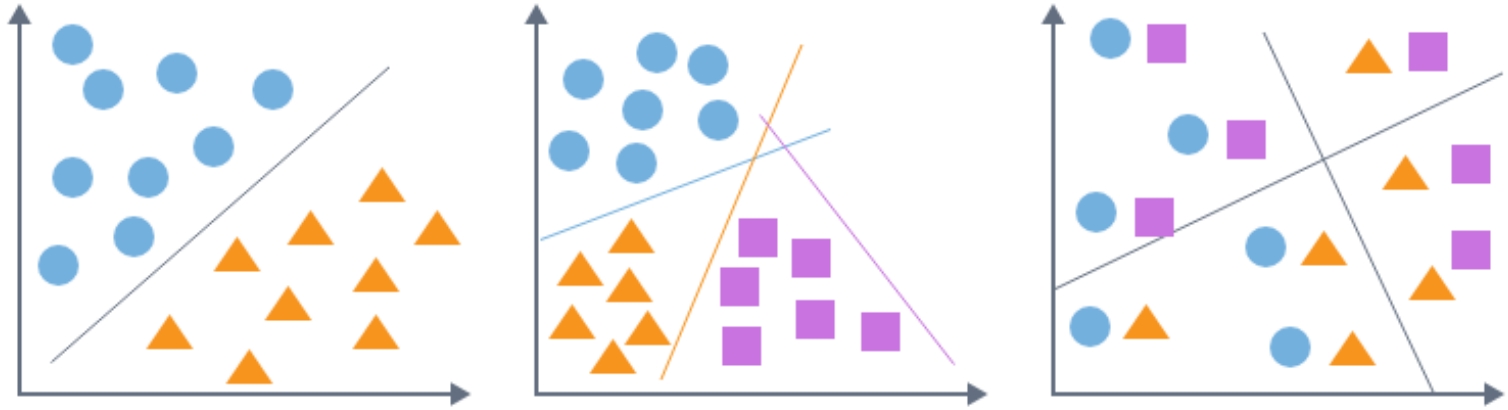

Бинарная классификация | Мультиклассовая классификация | Мультиметочная классификация

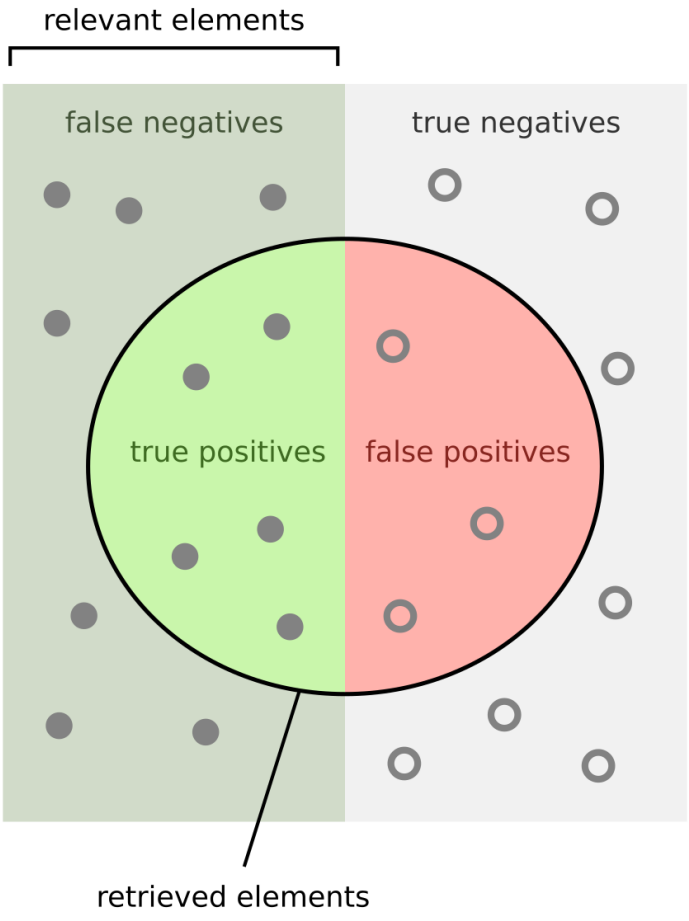

Метрики для оценки

- **True Positive (TP) — Истинно положительный**

Модель предсказала, что событие произошло, и оно действительно произошло.

Пример: Тест говорит, что человек болен, и он действительно болен.

- **True Negative (TN) — Истинно отрицательный**

Модель правильно предсказала отсутствие события. Всё идет по плану.

Пример: Тест говорит, что человек здоров, и он действительно здоров.

- **False Positive (FP) — Ложноположительный**

Ошибка 1-го рода («Ложная тревога»). Модель предсказала наличие события, но его на самом деле нет.

Пример: Тест говорит, что человек болен, но на самом деле он здоров.

- **False Negative (FN) — Ложноотрицательный**

Ошибка 2-го рода («Пропуск цели»). Модель предсказала, что события нет, но оно на самом деле есть.

Пример: Тест говорит, что человек здоров, но на самом деле он болен.

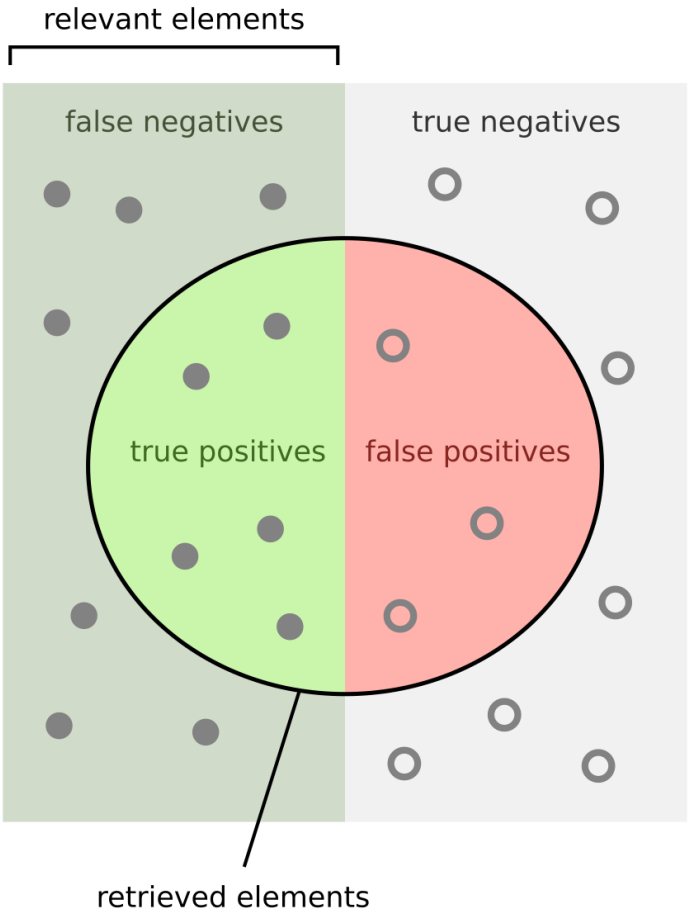

Почему это важно?

В зависимости от задачи, цена ошибки будет разной, это влияет на методологию решения:

- **В медицине (диагностика рака):**
  - Самая опасная ошибка — False Negative (сказать больному, что он здоров). Человек не получит лечения. В данной задаче стараются свести FN к минимуму.
- **В спам-фильтрах:**
  - Неприятная ошибка — False Positive (отправить важное письмо по работе в папку «Спам»). Лучше пропустить одно лишнее рекламное письмо во входящие (False Negative), чем потерять контракт.

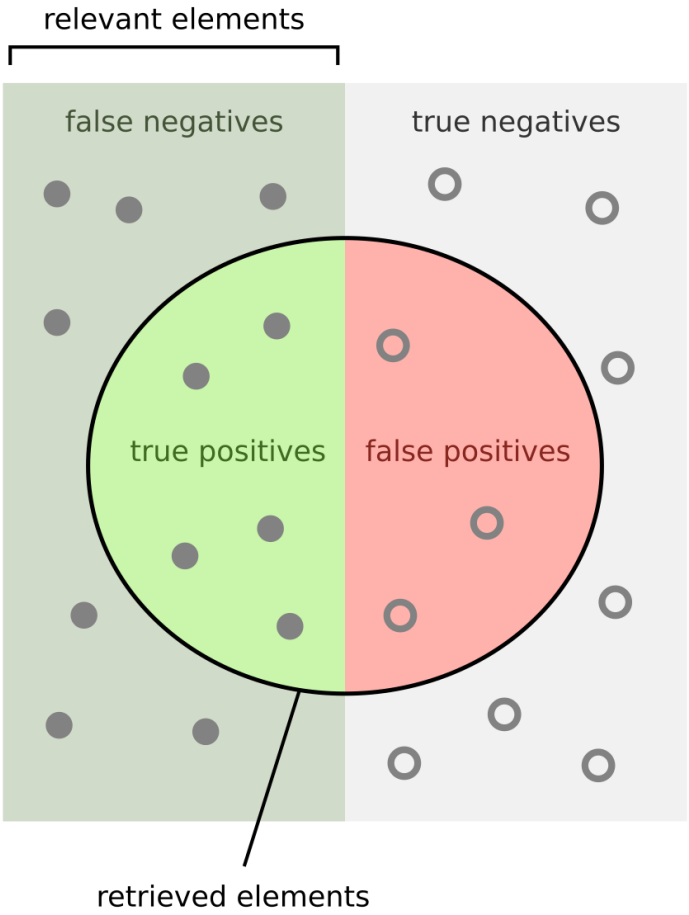

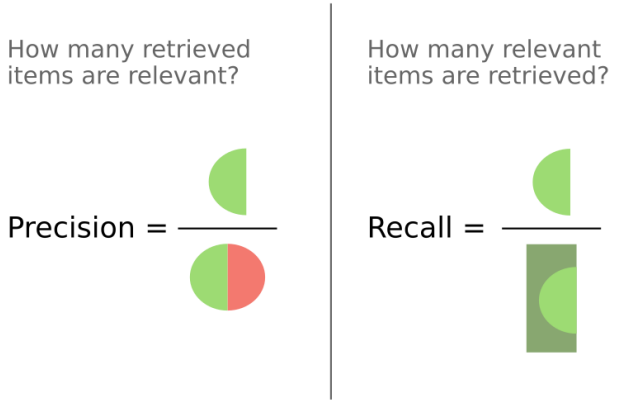

Расчёт метрик

- **Accuracy (Точность):** Общая доля правильных ответов.

$$Accuracy = \frac{TP + TN}{TP + FN + FP + TN}$$

- **Precision (Точность прогноза):** Как часто модель права, когда говорит «Да».

$$Precision = \frac{TP}{TP + FP}$$

- **Recall (Полнота):** Какую долю реальных «Да» модель смогла найти.

$$Recall = \frac{TP}{TP + FN}$$

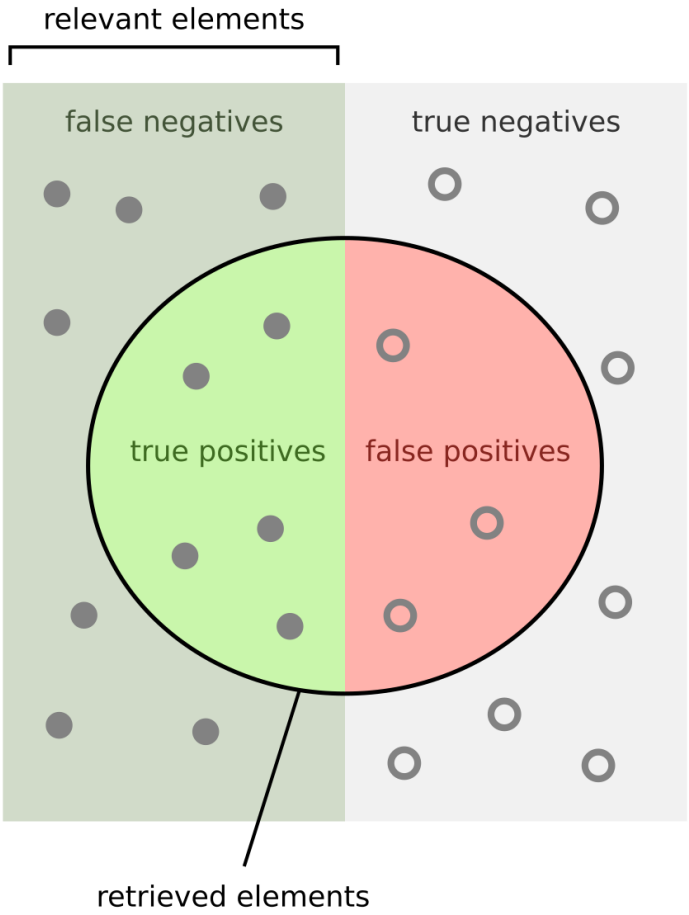

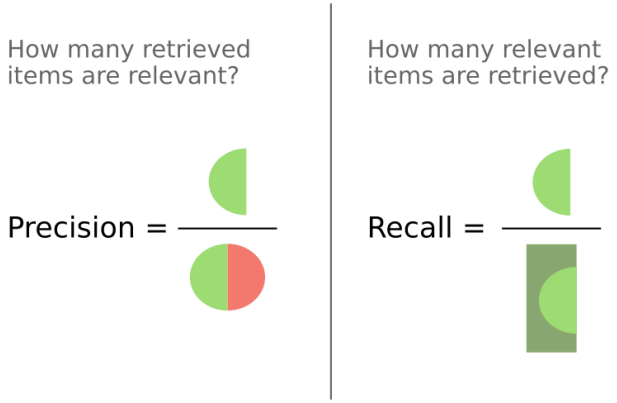

F1-score

- **F1-score (F-мера):** Это среднее гармоническое между Precision и Recall. Она помогает найти баланс между ними, так как обычно при попытке улучшить точность падает полнота, и наоборот.

$$F1 = 2 * \frac{Precision * Recall}{Precision + Recall}$$

$$F1 = \frac{2 * TP}{2 * TP + FN + FN}$$

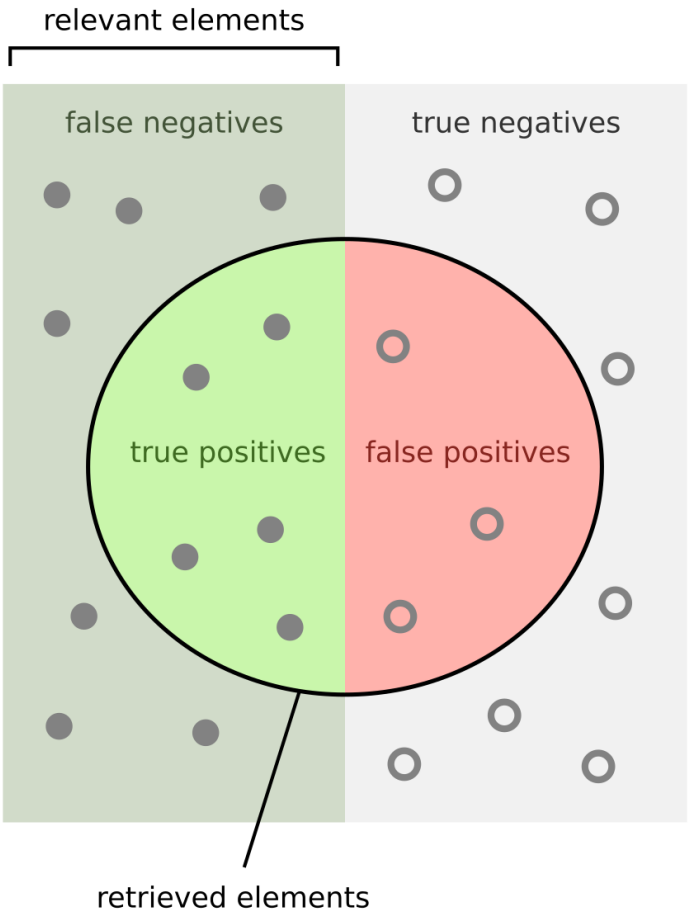

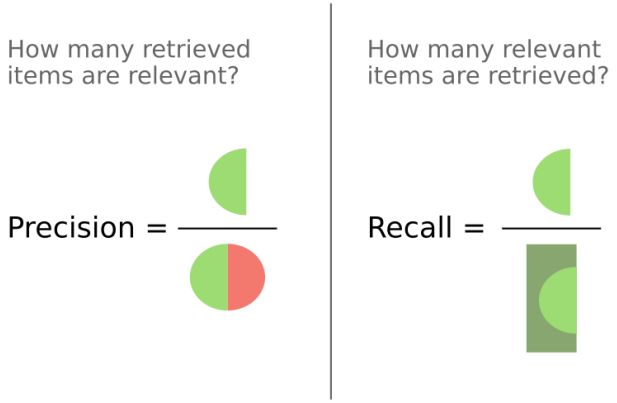

Когда на что смотрим?

- Если нам важно **не допустить ложных обвинений** (например, блокировка аккаунтов) — максимизируем **Precision**.
- Если нам важно **найти всех виновных** и не пропустить ни одного случая (например, поиск вируса или дефектов на производстве) — максимизируем **Recall**.
- Если нам нужен **единый показатель**, который учитывает обе ошибки — смотрим на **F1-score**.

Алгоритмы для задачи классификации

Линейная модель

Логистическая регрессия

К-ближайших соседей (k-NN)

Деревья решений

Random Forest

Метод опорных векторов (SVM)

Нейросети

Линейная модель классификации

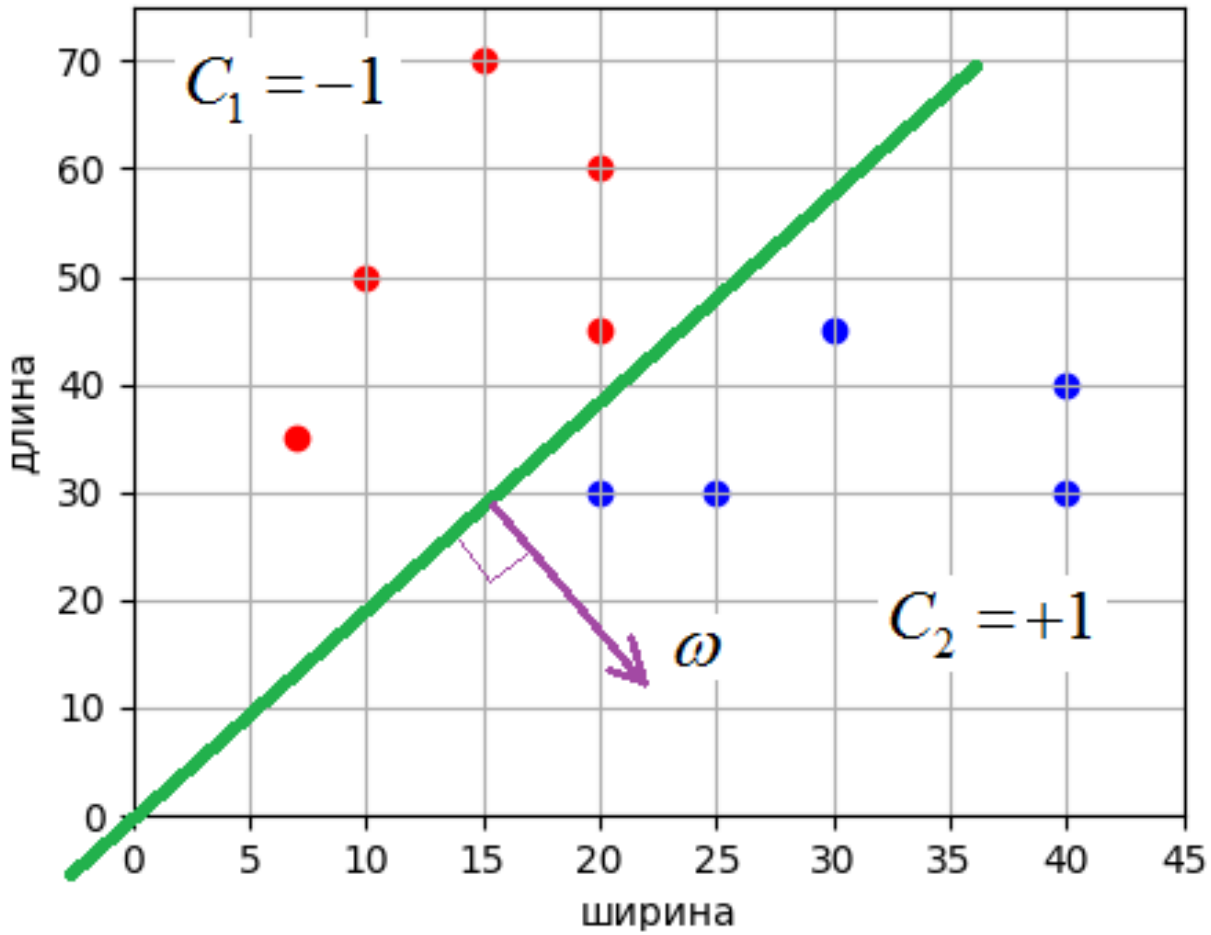

Линейные методы пытаются провести в пространстве данных прямую линию (или плоскость), которая четко разделяет классы друг от друга.

Разделяющая гиперплоскость

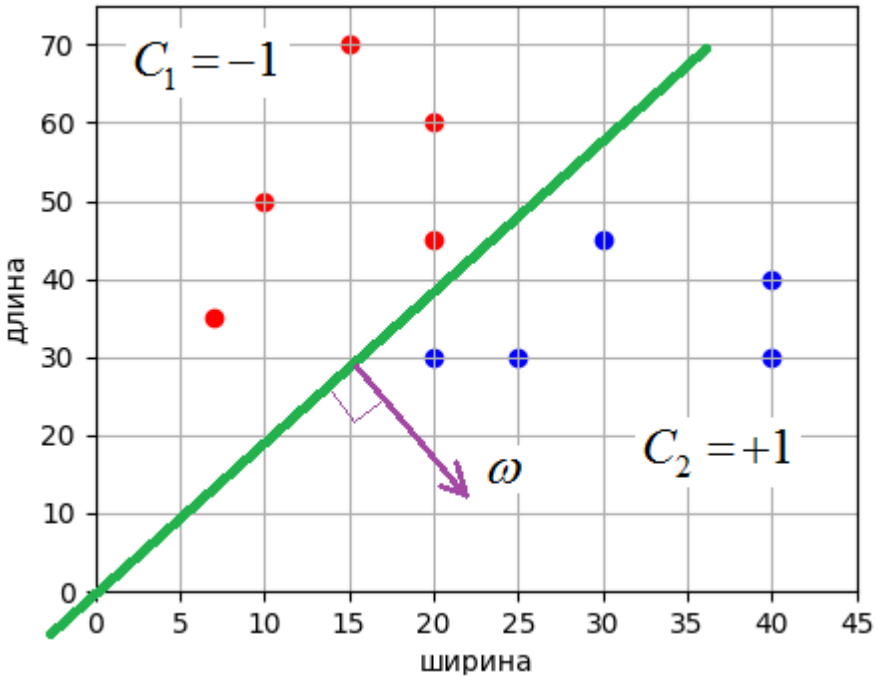

Смотрим на плоскость, на которой раскиданы
и красные точки. Линейная модель пытается п
прямую линию так, чтобы с одной стороны ока
синие, а с другой — только красные.

В математическом виде это выглядит как уравн

$$\hat{y} = w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + b$$

$x_1, x_2, \ldots, x_n$ — это признаки объекта (например, рост, вес).

$w_1, w_2, \ldots, w_n$ (веса) — это важность каждого признака, которую модель подбирает в процессе обучения.

b (смещение) — позволяет линии не проходить строго через начало координат.

Результат этого уравнения — число. Если оно больше нуля, мы относим объект к классу +1, если меньше — к классу -1.

Геометрический смысл

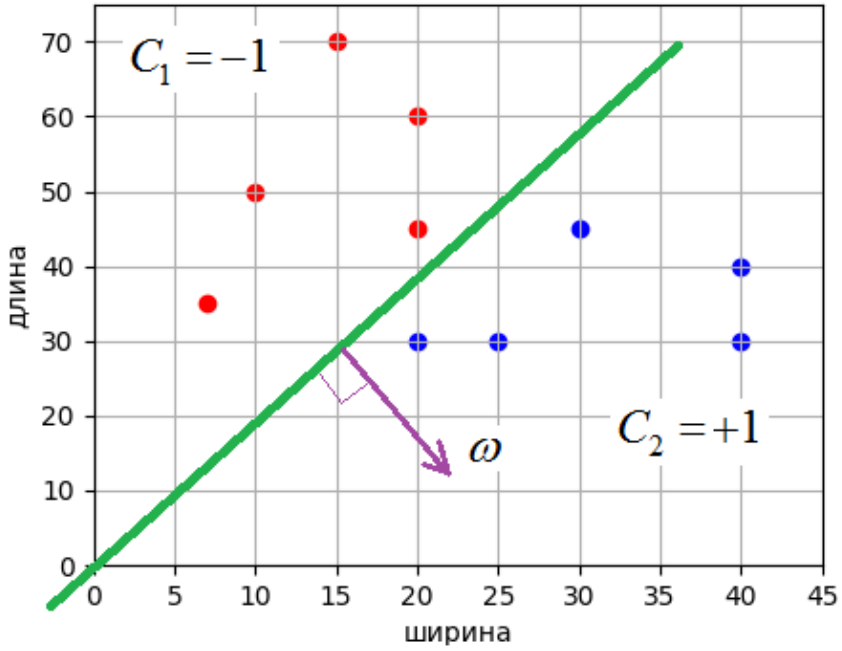

Вектор весов w : Это вектор, перпендикулярный нашей гиперплоскости (нормаль). Он указывает направление, в котором значение функции $f(x)$ растет быстрее всего. Изменяя веса, алгоритм меняет угол наклона границы.

Смещение b: Без этого параметра любая разделяющая линия обязана была бы проходить через точку $(0, 0, \ldots, 0)$. Смещение позволяет «двигать» плоскость параллельно самой себе, чтобы она могла пройти между классами, которые находятся далеко от начала координат.

Отступ объекта (Margin)

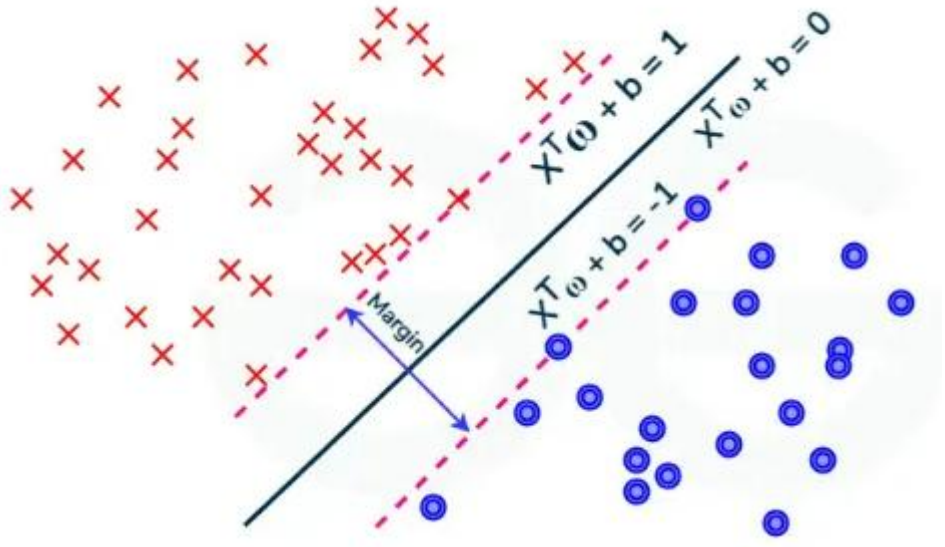

$$M_i = y_i(w^T x_i + b)$$

- y_i – это реальная метка класса (+1, -1)
- Если $M_i > 0$, модель классифицировала объект верно (знак предсказания совпал со знаком метки).
- Если $M_i < 0$, модель ошиблась.
- Абсолютное значение $|M_i|$ показывает, насколько далеко объект находится от границы. Чем больше $|M_i|$, тем «увереннее» модель.

Функции потерь в задачах классификации

- Логистическая функция потерь (Log-Loss):

$$L(M) = \ln(1 + e^{-M})$$

- Если отступ большой и положительный (уверенно верный ответ), ошибка стремится к нулю. Если отступ отрицательный (ошибка), штраф растет экспоненциально.
- **Особенность:** Эта функция гладкая и дифференцируемая, что позволяет легко использовать метод градиентного спуска.

Логистическая регрессия

Логистическая регрессия — это метод машинного обучения, который не просто строит линию, а предсказывает **вероятность** того, что объект относится к определенной категории.

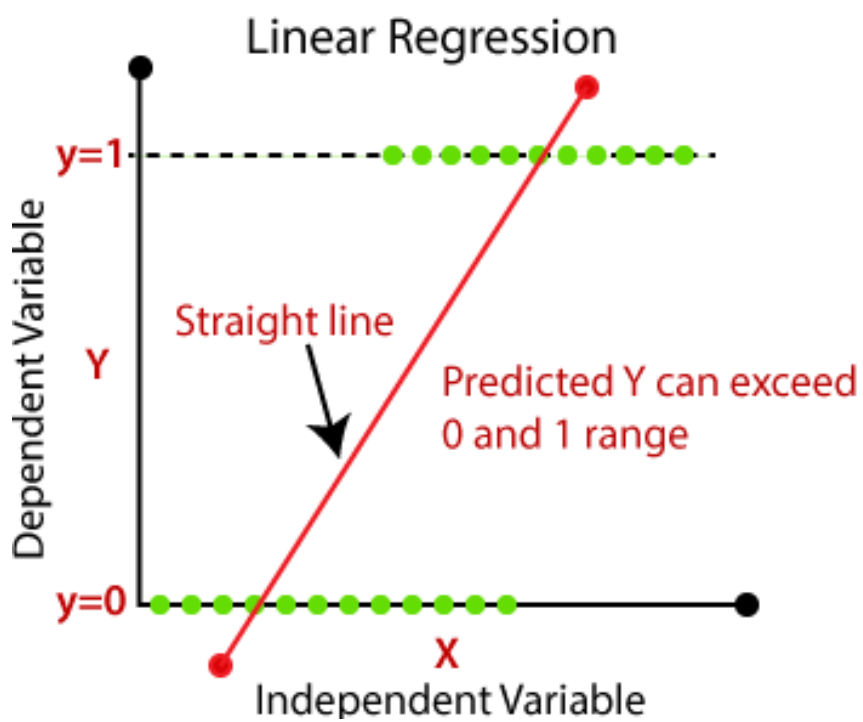

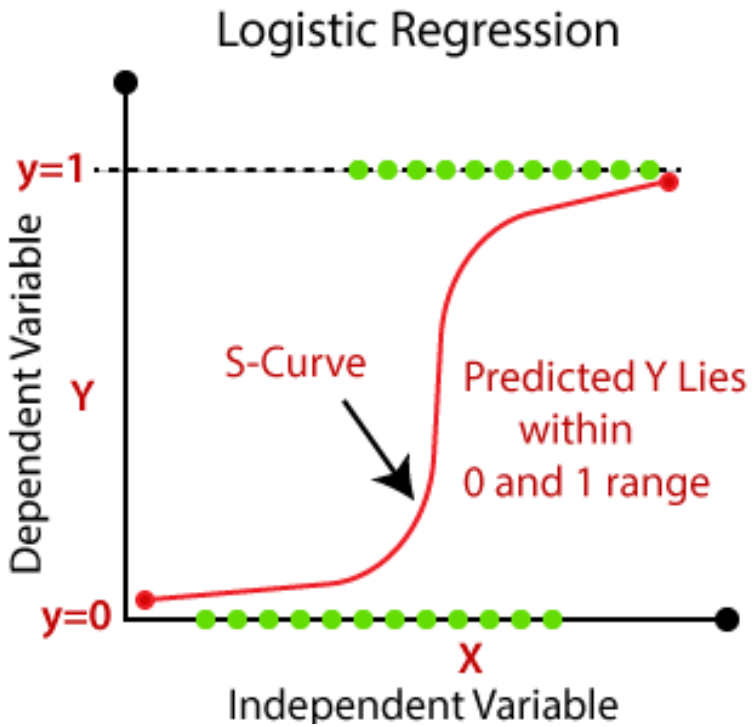

Логистическая регрессия

Примеры использования:

- Банки: Одобрить кредит или нет (вернет ли клиент деньги?).
- Медицина: Есть ли у пациента заболевание на основе симптомов и анализов.
- Маркетинг: Купит ли пользователь товар, кликнет ли по рекламе.
- Безопасность: Является ли транзакция мошеннической.

Алгоритм

1. Линейное предсказание

Сначала вычисляется линейная комбинация признаков x и весов w с добавлением смещения (bias) b:

$$z = w_1x_1 + w_2x_2 + ... + w_nx_n + b = w^Tx + b$$

2. Функция активации (Сигмоида)

Чтобы превратить любое число z в вероятность от 0 до 1, используется логистическая функция (сигмоида):

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

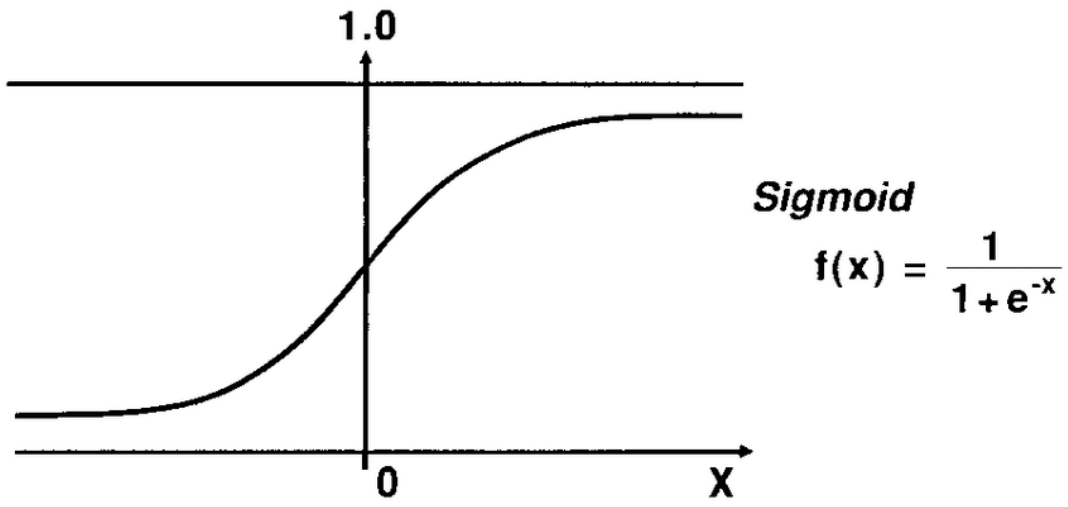

Результат $y' = \sigma(z)$ — это предсказанная вероятность того, что объект относится к классу «1».

Алгоритм

3. Функция потерь (Log Loss)

Для оценки ошибки используется логистическая функция потерь (Binary Cross-Entropy). Она сильно штрафует модель за уверенные, но неверные прогнозы:

$$L(y, y') = -\frac{1}{N}\sum_{i=1}^{N}[y_i \ln(y'_i) + (1 - y_i)\ln(1 - y'_i)]$$

Где y — реальная метка (0 или 1), а y' — предсказание модели.

Алгоритм

4. Обучение (Градиентный спуск)

Веса обновляются итеративно, чтобы минимизировать функцию потерь. На каждом шаге веса корректируются в сторону, противоположную градиенту:

$$w_{new} = w_{old} - \alpha \cdot \frac{\partial L}{\partial w}$$

Где α — скорость обучения (learning rate), а производная $\frac{\partial L}{\partial w}$ для каждого веса j выглядит на удивление просто:

$$\frac{\partial L}{\partial w_j} = \frac{1}{N} \sum_{i=1}^{N} (y'_i - y_i) x_{ij}$$