

TECHNOLOGIES IN EDUCATION
UNIVERSITY NSU

MICROELECTRONICS
INNOVATIONS
CATALYTIC
MATERIALS
ASSEMBLY
POINT

SCIENTIFIC
LABORATORY
HYBRID
MATERIALS
GEOPHYSICS
ENGINEERING
ENERGY CONSERVATION
BIOTECHNOLOGY
GEOCHEMISTRY
NANOTECHNOLOGY

HIGH
ENERGIES
SEMIOTICS
SCIENCE
MATHEMATICAL MODELING

DEVELOPMENT
ELEMENTARY
PARTICLES
THE ARCTIC REGIONS
DARK
MATTER

QUANTUM
TECHNOLOGIES
BIOMEDICINE
APPLIED
STUDIES
PHOTONICS
ASTRONOMY
GLOBAL PRIORITY
ASTROPHYSICS
BIOINFORMATICS

LASER
PHYSICS
KNOWLEDGE
ECONOMY
GEOLOGY
ARCHEOLOGY
COGNITIVE TECHNOLOGIES
STUDY
BRAIN
IT
DEEP
LEARNING

N* Novosibirsk
State
University
*THE REAL SCIENCE



Машинное обучение

Семинар 14

Глушенко Андрей Валерьевич
Институт Интеллектуальной
Робототехники


Бустинг

Бустинг (Boosting) — это семейство ансамблевых алгоритмов машинного обучения, основанных на последовательном объединении «слабых» моделей (weak learners) в одну «сильную». В отличие от бэггинга, где модели обучаются независимо, в бустинге каждая последующая модель строится таким образом, чтобы минимизировать ошибки предыдущих.



AdaBoost (Adaptive Boosting)

AdaBoost был первым успешным алгоритмом бустинга. Его основная идея заключается в адаптивном изменении весов объектов обучающей выборки.



AdaBoost.M1

Механизм: На каждой итерации алгоритм назначает бóльшие веса тем примерам, которые были неверно классифицированы предыдущими моделями. Таким образом, новая модель вынуждена фокусироваться на «сложных» случаях.

1. Инициализация весов объектов

В начале обучения всем N объектам присваиваются равные веса:

$$w_i^{(1)} = \frac{1}{N}, \quad i = 1, \dots, N$$

2. Ошибка слабой модели

На каждой итерации t вычисляется взвешенная ошибка классификатора h_t :

$$\epsilon_t = \frac{\sum_{i=1}^N w_i^{(t)} \cdot \mathbb{I}(y_i \neq h_t(x_i))}{\sum_{i=1}^N w_i^{(t)}}$$

AdaBoost.M1

3. Коэффициент важности модели (Weight of evidence)

Вес самой модели в финальном ансамбле рассчитывается на основе её ошибки:

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right)$$

4. Обновление весов объектов

Веса объектов пересчитываются так, чтобы увеличить значимость тех, на которых модель ошиблась:

$$w_i^{(t+1)} = w_i^{(t)} \cdot \exp \left(\alpha_t \cdot \mathbb{I}(y_i \neq h_t(x_i)) \right)$$

AdaBoost.M1

5. Нормировка весов

Чтобы сумма весов оставалась равной 1:

$$w_i^{(t+1)} = \frac{w_i^{(t)}}{\sum_{j=1}^N w_j^{(t)}}$$


6. Финальный классификатор

Итоговое решение принимается путем взвешенного голосования:

$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right)$$

AdaBoost (Adaptive Boosting)

AdaBoost был первым успешным алгоритмом бустинга. Его основная идея заключается в адаптивном изменении весов объектов обучающей выборки.



Бустинг в задачах регрессии

При переходе от классификации к регрессии (прогнозированию числового значения) меняется способ коррекции ошибок.

- Вместо изменения весов объектов алгоритм настраивается на остатки (residuals) — разность между истинным значением y и текущим предсказанием ансамбля.
- Для AdaBoost в регрессии (AdaBoost.R2) используется специфическая функция потерь (линейная, квадратичная или экспоненциальная) для оценки относительной ошибки каждого объекта, на основе которой корректируются веса.

Бустинг в задачах регрессии

Линейная функция потерь:

$$e_{it} = \frac{|y_i - h_t(x_i)|}{D_t}$$

Квадратичная функция потерь:

$$e_{it} = \frac{|y_i - h_t(x_i)|^2}{D_t^2}$$

Экспоненциальная функция потерь:

$$e_{it} = 1 - \exp\left(-\frac{|y_i - h_t(x_i)|}{D_t}\right)$$

Бустинг в задачах регрессии

После вычисления e_{it} средняя ошибка итерации считается как:

$$\bar{e}_t = \sum_{i=1}^N w_i^{(t)} e_{it}$$

А веса объектов обновляются по формуле:

$$w_i^{(t+1)} = w_i^{(t)} \cdot \beta_t^{(1-e_{it})}, \quad \text{где } \beta_t = \frac{\bar{e}_t}{1 - \bar{e}_t}$$

Экспоненциальная функция потерь:

$$e_{it} = 1 - \exp\left(-\frac{|y_i - h_t(x_i)|}{D_t}\right)$$

Градиентный бустинг (Gradient Boosting Machine, GBM)


GBM — это обобщение бустинга, позволяющее оптимизировать любую дифференцируемую функцию потерь $L(y, \hat{y})$.

Принцип: Вместо изменения весов, каждая последующая модель обучается предсказывать антиградиент функции потерь относительно текущих ответов ансамбля.

Математическая суть: Мы рассматриваем процесс построения ансамбля как градиентный спуск в пространстве функций. Каждое новое «дерево» добавляет вектор, который максимально приближает прогноз к минимуму функции потерь.

Градиентный бустинг (Gradient Boosting Machine, GBM)


Итерация: $\widehat{y}_i^{(t)} = \widehat{y}_i^{(t-1)} + \eta \cdot h_t(x_i)$, где η – темп обучения (learning rate), а h_t – модель, обученная на градиентах.



Стохастический градиентный бустинг (SGB)

Это модификация GBM, предложенная Джеромом Фридманом для борьбы с переобучением и ускорения процесса обучения.

Метод: На каждой итерации очередная слабая модель обучается не на всей выборке, а на её случайном подмножестве (подвыборке без возвращения).



Стохастический градиентный бустинг (SGB)

Преимущества:

- **Регуляризация:** Внесение случайности снижает корреляцию между деревьями, что улучшает обобщающую способность модели.
- **Эффективность:** Требуется меньше вычислительных ресурсов на каждой итерации.

Параметр: Основным параметром является `subsample` (доля выборки, обычно от 0.5 до 0.8).